

Lista de Exercícios 1

Professor(a): Eduardo Mendes

Aluno: Franklin Alves de Oliveira

Exercise 1 (Inversion and Rejection)

1. Let $Y \sim \text{Exp}(\lambda)$ and $a > 0$. We consider the variable after restricting its support to be $[a, +\infty)$. That is, let $X = Y \mid Y \geq a$, i.e., X has the law of Y conditionally on being in $[a, +\infty)$. Calculate $F_X(x)$, the cumulative distribution function of X , and $F_X^{-1}(u)$, the quantile function of X . Describe an algorithm to simulate X from $U \sim \mathcal{U}_{[0,1]}$.

Solução:

Para resolver essa questão, vamos tomar como base o resultado do seguinte teorema:

Teorema Fundamental da Simulação: Seja F uma CDF contínua e estritamente crescente. Então, existe $F^{-1} : [0, 1] \rightarrow \mathbb{R}$ e valem os seguintes resultados:

1. $U \sim \mathcal{U}_{(0,1)}$ e $X = F^{-1}(U) \Rightarrow X$ é uma variável aleatória com CDF F .
2. Se X é uma variável aleatória contínua com CDF F , então $F(X) \sim \mathcal{U}_{[0,1]}$.

Assim, se Y é uma v.a. tal que $Y \sim \text{Exp}(\lambda)$, então Y tem PDF $f_Y(y) = \lambda e^{-\lambda y}$, com $\text{supp}(Y) = [0, +\infty)$. Definindo $X = Y \mid Y \geq a$, onde $a > 0$, temos:

$$F_X(x) = P(X \leq x) = P(Y \leq x \mid Y \geq a) \quad (1)$$

Aplicando a Regra de Bayes, podemos reescrever 1 da seguinte forma:

$$\begin{aligned} F_X(x) &= P(Y \leq x \mid Y \geq a) = \frac{P(a \leq Y \leq x)}{P(Y \geq a)} = \frac{\int_a^x \lambda e^{-\lambda y} dy}{\int_0^{+\infty} \lambda e^{-\lambda y} dy} = \\ &= \frac{-e^{-\lambda x} + e^{-\lambda a}}{-e^{-\lambda a}} = \frac{e^{-\lambda a} - e^{-\lambda x}}{e^{-\lambda a}} = 1 - \frac{e^{-\lambda x}}{e^{-\lambda a}} = 1 - e^{-\lambda(x-a)} \end{aligned} \quad (2)$$

Pelo **Teorema Fundamental da Simulação**, sabemos que $F_x(x) = U \sim \mathcal{U}_{[0,1]}$. Então, podemos "simular" X fazendo $X = F_x^{-1}(U)$. Ainda, podemos determinar F_x^{-1} resolvendo a seguinte equação para x :

$$F_x(x) = U = 1 - e^{-\lambda(x-a)} \quad (3)$$

Assim,

$$\begin{aligned} U - 1 &= -e^{-\lambda(x-a)} \Rightarrow 1 - U = e^{-\lambda(x-a)} \Rightarrow \\ \Rightarrow \log(1 - U) &= -\lambda(x - a) \Rightarrow -\frac{\log(1 - U)}{\lambda} = x - a \Rightarrow x = a - \frac{\log(1 - U)}{\lambda} \end{aligned} \quad (4)$$

Portanto, definimos $F_X^{-1}(U) = a - \frac{\log(1-U)}{\lambda}$. Logo, para simular X , tome os seguintes passos:

1. Simule $U \sim \mathcal{U}_{[0,1]}$.
2. A partir do valor gerado de U , determine $X = a - \frac{\log(1-U)}{\lambda}$.

2. Let a and b be given, with $a < b$. Show that we can simulate $X = Y \mid a \leq Y \leq b$ from $U \sim \mathcal{U}_{[0,1]}$ using

$$X = F_Y^{-1}(F_Y(a)(1-U) + F_Y(b)U),$$

i.e., show that if X is given by the formula above, then $\Pr(X \leq x) = \Pr(Y \leq x \mid a \leq Y \leq b)$. Apply the formula to simulate an exponential random variable conditioned to be greater than a , as in the previous question.

Solução:

Sejam a e b dados, com $a < b$. Se X é uma v.a. tal que

$$X = F_Y^{-1}(F_Y(a)(1-U) + F_Y(b)U), \text{ então}$$

$$F_X(x) = P(X \leq x) = P(F_Y^{-1}(F_Y(a)(1-U) + F_Y(b)U) \leq x) \quad (5)$$

Aplicando F_Y em ambos os lados da desigualdade em 5, temos:

$$\begin{aligned} F_X(x) &= P(X \leq x) = P((F_Y(a)(1-U) + F_Y(b)U) \leq F_Y(x)) = \\ &P(F_Y(a) - F_Y(a)U + F_Y(b)U \leq F_Y(x)) = P((F_Y(b) - F_Y(a))U \leq F_Y(x) - F_Y(a)) = \\ &P\left(U \leq \frac{F_Y(x) - F_Y(a)}{F_Y(b) - F_Y(a)}\right) = \frac{F_Y(x) - F_Y(a)}{F_Y(b) - F_Y(a)}. \end{aligned} \quad (6)$$

Agora, vamos aplicar essa fórmula no caso em que $Y \sim \mathcal{Exp}(\lambda)$. Assim, Y tem PDF $f_Y(y) = \lambda e^{-\lambda y}$, e sua CDF é:

$$F_Y(y) = \int_0^{+\infty} \lambda e^{-\lambda y} dy = 1 - e^{-\lambda y}$$

Se condicionarmos Y a $Y > a > 0$, fizermos $b \rightarrow +\infty$ de forma que $F_Y(b) = 1$ e, ainda, tomando $U \sim \mathcal{U}_{[0,1]}$, temos:

$$F_Y(a)(1-U) + F_Y(b)U = (1 - e^{-\lambda a})(1-U) + U$$

e, portanto,

$$X = F_Y^{-1}(F_Y(a)(1-U) + F_Y(b)U) = F_Y^{-1}\left((1 - e^{-\lambda a})(1-U) + U\right) \quad (7)$$

Sabemos que, se $A = F_Y(y) = 1 - e^{-\lambda y}$, então $F_Y^{-1} = -\frac{\log(1-A)}{\lambda}$. Assim, podemos reescrever 7 como:

$$\begin{aligned} X &= -\lambda^{-1} \log(1 - [F_Y(a)(1-U) + F_Y(b)U]) = -\lambda^{-1} \log\left(1 - \left[(1 - e^{-\lambda a})(1-U) + U\right]\right) = \\ &= -\lambda^{-1} \log\left(1 - \left(1 - e^{-\lambda a} - U + Ue^{-\lambda a} + U\right)\right) = -\lambda^{-1} \log e^{-\lambda a} (1-U) = \\ &= -\lambda^{-1}(-\lambda a) + -\lambda^{-1} \log(1-U) = a - \lambda^{-1} \log(1-U) \end{aligned} \quad (8)$$

como já havíamos encontrado na questão 1.

3. Here is a simple algorithm to simulate $X = Y \mid Y > a$ for $Y \sim \text{Exp}(\lambda)$:

- (a) Let $Y \sim \text{Exp}(\lambda)$. Simulate $Y = y$.
- (b) If $Y > a$ then stop and return $X = y$, and otherwise, start again at step (a).

Show that this is just a rejection algorithm, by writing the proposal and target densities π and q , as well as the bound $M = \max_x \pi(x)/q(x)$. Calculate the expected number of trials to the first acceptance. Why is inversion to be preferred for $a \gg 1/\lambda$?

Solução:

Defina a variável aleatória $Y \sim \text{Exp}(\lambda)$. Como, no primeiro passo do algoritmo, estamos amostrando de uma exponencial com parâmetro λ , a nossa distribuição proposta é a PDF de Y , i.e.,

$$q(y) = \lambda e^{-\lambda y}, \text{ onde } y \geq 0.$$

Em particular, estamos interessados nos casos em que $y \geq a > 0$. Logo, nossa distribuição alvo (*Target*) é:

$$\pi(y) = \lambda e^{-\lambda(y-a)} \mathbf{1}_{y \geq a}$$

Note que $\pi(y) = \lambda e^{-\lambda(y-a)} \mathbf{1}_{y \geq a} \leq q(y) = \lambda e^{-\lambda y}$, para todo $y \geq 0$. Não obstante, definindo $M = \max_x \pi(x)/q(x)$, onde $X = Y \mid Y \geq a$.

Note que o valor máximo da razão $\pi(x)/q(x)$ acontece quando $\pi(x)$ é máximo e $q(x)$ é mínimo. Porém, tanto $\pi(x)$ quanto $q(x)$ são decrescentes em x , sendo que $q(x)$ decresce mais rápido com um incremento em x do que $\pi(x)$. Logo, o máximo da razão entre as duas funções acontece quando o valor de x é mínimo. Como o suporte de X é $[a, +\infty)$, o máximo de $\pi(x)/q(x)$ acontece quando $X = a$. Assim,

$$M = \max_x \pi(x)/q(x) = \pi(a)/q(a) = \lambda e^{-\lambda(a-a)} / \lambda e^{-\lambda a} = e^{\lambda a}.$$

Denotando por α a probabilidade de aceitação do algoritmo, temos

$$\alpha = \frac{\pi(y)}{Mq(y)} = \begin{cases} 1 & \text{se } y \geq a \\ 0 & \text{caso contrário} \end{cases} \quad (9)$$

Isso quer dizer que, segundo esse algoritmo, sempre aceitamos se $y \geq a$.

Por definição, o número de tentativas até o primeiro sucesso (n) segue uma distribuição geométrica(p), onde p é a probabilidade de sucesso, i.e., $p = P(Y \geq a)$. Logo,

$$p = P(Y \geq a) = 1 - P(Y < a) = 1 - \int_0^a \lambda e^{-\lambda y} dy = 1 - \left[-e^{-\lambda y} \right]_0^a = 1 - (1 - e^{-\lambda a}) = e^{-\lambda a}.$$

Assim, $\mathbb{E}[n] = 1/p = e^{\lambda a}$.

Exercise 2 (Rejection)

Consider the following "squeeze" rejection algorithm for sampling from a distribution with density $\pi(x) = \tilde{\pi}(x)/Z_\pi$ on a state space \mathbb{X} such that

$$h(x) \leq \tilde{\pi}(x) \leq M\tilde{q}(x)$$

where h is a non-negative function, $M > 0$ and $q(x) = \tilde{q}(x)/Z_q$ is the density of a distribution that we can easily sample from. The algorithm proceeds as follows:

- (a) Draw independently $X \sim q$, $U \sim \mathcal{U}_{[0,1]}$.
- (b) Accept X if $U \leq h(X)/(M\tilde{q}(X))$.
- (c) If X was not accepted in step (b), draw an independent $V \sim \mathcal{U}_{[0,1]}$ and accept X if .

$$V \leq \frac{\tilde{\pi}(X) - h(X)}{M\tilde{q}(X) - h(X)}$$

1. Show that the probability of accepting a proposed $X = x$ in either step (b) or (c) is

$$\frac{\tilde{\pi}(x)}{M\tilde{q}(x)}.$$

Solução:

Ora,

$$P(\text{aceitar } x \text{ no passo (b)}) = \int_0^1 \mathbb{1}_{\left(U \leq \frac{h(x)}{M\tilde{q}(x)}\right)} dU = \frac{h(x)}{M\tilde{q}(x)} \quad (10)$$

Analogamente,

$$\begin{aligned} P(\text{aceitar } x \text{ no passo (c)}) &= \int_0^1 \int_0^1 \mathbb{1}_{\left(U > \frac{h(x)}{M\tilde{q}(x)}\right)} \mathbb{1}_{\left(V \leq \frac{\tilde{\pi}(X) - h(X)}{M\tilde{q}(X) - h(X)}\right)} dU dV = \\ &= \left(1 - \frac{h(x)}{M\tilde{q}(x)}\right) \left(\frac{\tilde{\pi}(X) - h(X)}{M\tilde{q}(X) - h(X)}\right) = \frac{\tilde{\pi}(x) - h(x)}{M\tilde{q}(x)} \end{aligned} \quad (11)$$

□

2. Deduce from the previous question that the distribution of the samples accepted by the above algorithm is π .

Solução:

Considerando $A \subset \mathbb{X}$ um conjunto mensurável, pelo método de *Rejection Sampling*, temos:

$$P(X \in A \mid X \text{ aceito}) = \frac{P(X \in A, X \text{ aceito})}{P(X \text{ aceito})}$$

Note que,

$$P(X \in A, X \text{ aceito}) = \int_{\mathbb{X}} \int_0^1 \mathbb{1}_{(x \in A)} \mathbb{1}_{\left(u \leq \frac{\pi(x)}{M \cdot q(x)}\right)} q(x) du dx =$$

$$= \int_{\mathbb{X}} \mathbb{1}_{(x \in A)} \frac{\pi(x)}{M \cdot q(x)} q(x) dx = \int_{\mathbb{X}} \mathbb{1}_{(x \in A)} \frac{\pi(x)}{M} dx = \frac{\pi(A)}{M}. \quad (12)$$

Ainda,

$$P(X \text{ aceito}) = P(X \in \mathbb{X}, X \text{ aceito}) = \frac{\pi(\mathbb{X})}{M} = \frac{1}{M}. \quad (13)$$

Combinando os resultados em 12 e 13, temos:

$$P(X \in A \mid X \text{ aceito}) = \frac{\pi(A)/M}{1/M} = \pi(A). \quad (14)$$

Com isso, concluímos que a distribuição dos valores aceitos é, exatamente, π .

3. Show that the probability that step (c) has to be carried out is

$$1 - \frac{\int_{\mathbb{X}} h(x) dx}{MZ_q}$$

Solução:

Ora,

$$\begin{aligned} P(\text{passo (c) ser executado}) &= P(X \text{ ser rejeitado no passo (b)}) = \int_0^1 \int_{\mathbb{X}} \mathbb{1}_{(U > \frac{h(x)}{M\tilde{q}(x)})} q(x) dx dU \\ &= \int_{\mathbb{X}} \left(1 - \frac{h(x)}{M\tilde{q}(x)}\right) q(x) dx = \int_{\mathbb{X}} q(x) - q(x) \frac{h(x)}{M\tilde{q}(x)} dx = \int_{\mathbb{X}} q(x) dx - \int_{\mathbb{X}} q(x) \frac{h(x)}{M\tilde{q}(x)} dx = \\ &= 1 - \int_{\mathbb{X}} \frac{h(x)}{MZ_q} dx, \end{aligned} \quad (15)$$

Dado que $q(x) = \tilde{q}(x)/Z_q$.

4. Let $\tilde{\pi}(x) = \exp(-x^2/2)$ and $\tilde{q}(x) = \exp(-|x|)$. Using the fact that

$$\tilde{\pi}(x) \geq 1 - \frac{x^2}{2}$$

for any $x \in \mathbb{R}$, how could you use the squeeze rejection sampling algorithm to sample from $\pi(x)$. What is the probability of not having to evaluate $\tilde{\pi}(x)$? Why could it be beneficial to use this algorithm instead of the standard rejection sampling procedure?

Solução:

Para aplicar o método *Squeeze Rejection Sampling*, precisamos que a seguinte relação seja válida:

$$h(x) \leq \tilde{\pi}(x) \leq M\tilde{q}(x) \quad (16)$$

Onde $h(x)$ é uma função não-negativa, i.e., $x \leq \pm\sqrt{2}$. O enunciado nos sugere que $\tilde{\pi}(x) \geq 1 - x^2/2$, $\forall x \in \mathbb{R}$. Então, convenientemente, podemos definir $h(x) = 1 - x^2/2$. Para definir o valor de M , tome:

$$M = \sup_{x \in \mathbb{X}} \tilde{\pi}(x)/\tilde{q}(x) = \sup_{x \in \mathbb{X}} \exp(-x^2/2) \exp(-|x|)^{-1} = \sup_{x \in \mathbb{X}} \exp(-x^2/2 + |x|) =$$

Para $x \geq 0$, temos:

$$M = \sup_{x \in \mathbb{X}} \exp(-x^2/2 + x) = \exp\left(\max_{x \in \mathbb{X}} (-x^2/2 + x)\right)$$

Aplicando a condição de primeira ordem para maximizar a função $-x^2/2 + x$, encontramos:

$$\frac{d(-x^2/2 + x)}{dx} = -x + 1 = 0 \iff x = 1$$

Logo,

$$M = \exp(-(1^2)/2 + 1) = \sqrt{e} \quad (17)$$

Fazendo as devidas substituições em 16, obtemos:

$$0 \leq 1 - x^2/2 \leq \tilde{\pi}(x) \leq \sqrt{e} \tilde{q}(x) \quad (18)$$

Assim, podemos aplicar o método *Squeeze Rejection Sampling* da seguinte forma:

- (a) Simulamos $U \sim \mathcal{U}_{[0,1]}$ e $X \sim \tilde{q}$
- (b) Verificamos se $u \leq \frac{h(x)}{M\tilde{q}(x)}$, i.e., $u \leq \frac{1-x^2/2}{\sqrt{e}\tilde{q}(x)}$. Se sim, aceitamos X . Caso contrário, seguimos para o passo (c).
- (c) Geramos $v \sim \mathcal{U}_{[0,1]}$ e aceitamos X se $v \leq \frac{\tilde{\pi}(x)-h(x)}{M\tilde{q}(x)-h(x)} = \frac{\tilde{\pi}(x)-(1-x^2/2)}{\sqrt{e}\tilde{q}(x)-(1-x^2/2)}$.

Lembrando que não teremos que avaliar $\tilde{\pi}(x)$ se X for aceito no passo (b). Então,

$$P(\text{não avaliar } \tilde{\pi}(x)) = P(\text{passo (c) não ser executado}) = 1 - \frac{\int_X h(x)dx}{MZ_q}, \quad (19)$$

Como já havíamos mostrado no item 3. Por definição, $Z_q = \int_X \tilde{q}(x)dx$. Logo,

$$Z_q = \int_X \exp(-|x|)dx = 2 \int_0^{+\infty} \exp(-x)dx = 2 [-e^{-x}]_0^{+\infty} = 2 [0 - (-1)] = 2 \quad (20)$$

Agora, fazendo as devidas substituições em 19, temos:

$$\begin{aligned} P(\text{não avaliar } \tilde{\pi}(x)) &= 1 - \frac{\int_{-\sqrt{2}}^{\sqrt{2}} 1 - x^2/2 \, dx}{\sqrt{e} \, 2} = 1 - \frac{[x - x^3/6]_{-\sqrt{2}}^{\sqrt{2}}}{\sqrt{e} \, 2} = 1 - \frac{2\sqrt{2} - 2\sqrt{2}^3/6}{\sqrt{e} \, 2} = \\ &= 1 - \frac{2\sqrt{2} - 2\sqrt{2}/3}{\sqrt{e} \, 2} = 1 - \frac{6\sqrt{2}/3 - 2\sqrt{2}/3}{\sqrt{e} \, 2} = 1 - \frac{4\sqrt{2}/3}{\sqrt{e} \, 2} = \frac{\sqrt{e} - 2\sqrt{2}/3}{\sqrt{e}} \end{aligned} \quad (21)$$

□

Vale destacar que, como $h(x)$ é computacionalmente menos custosa de avaliar do que $\tilde{\pi}(x)$, em média, esse método terá menos custo computacional do que o *Rejection Sampling* tradicional.

Exercise 3 (Transformation)

Consider the following algorithm known as Marsaglia's polar method.

- **Step a:** Generate independent U_1, U_2 according to $\mathcal{U}_{[-1,1]}$ until $Y = U_1^2 + U_2^2 \leq 1$.

- **Step b:** Define

$$Z = \sqrt{-2 \log(Y)}$$

and return

$$X_1 = Z \frac{U_1}{\sqrt{Y}}, \quad X_2 = Z \frac{U_2}{\sqrt{Y}}.$$

1. Define $\vartheta = \arctan(U_2/U_1)$. Show that the joint distribution of Y and ϑ has density

$$f_{Y,\vartheta}(y, \theta) = \mathbb{1}_{[0,1]}(y) \frac{\mathbb{1}_{[-\frac{\pi}{2}, \frac{\pi}{2}]}(\theta)}{2\pi}$$

Solução:

Considere $U_1, U_2 \sim \mathcal{U}_{[-1,1]}$ independentes. Agora, defina $Y = U_1^2 + U_2^2 \leq 1$ e $\vartheta = \arctan(U_2/U_1)$. Podemos definir a transformação $T : [-1, 1] \times [-1, 1] \rightarrow [0, 1] \times [-\frac{\pi}{2}, \frac{\pi}{2}]$ como:

$$T(U_1, U_2) = (U_1^2 + U_2^2, \arctan(U_2/U_1))$$

É fácil verificar que a função \arctan estritamente crescente e, portanto, inversível. Como, para quaisquer pares distintos (\bar{U}_1, \bar{U}_2) e $(\tilde{U}_1, \tilde{U}_2)$, $T(\bar{U}_1, \bar{U}_2) \neq T(\tilde{U}_1, \tilde{U}_2)$ (é garantido que ao menos as segundas coordenadas de $(U_1^2 + U_2^2, \arctan(U_2/U_1))$ serão distintas), concluímos que a transformação T é inversível. Agora, vamos determinar a transformação inversa T^{-1} .

Faremos isso resolvendo o seguinte sistema para U_1 e U_2 :

$$\begin{cases} Y = U_1^2 + U_2^2 \\ \vartheta = \arctan(U_2/U_1) \end{cases} \quad (22)$$

Da segunda equação, encontramos:

$$\tan(\vartheta) = \frac{U_2}{U_1} \Rightarrow U_2 = U_1 \tan(\vartheta) \quad (23)$$

Substituindo o resultado de 23 na primeira equação de 22, encontramos:

$$\begin{aligned} Y &= U_1^2 + U_1^2 \tan^2(\vartheta) = U_1^2 (1 + \tan^2(\vartheta)) = U_1^2 \left(1 + \frac{\sin^2(\vartheta)}{\cos^2(\vartheta)}\right) = U_1^2 \left(\frac{\cos^2(\vartheta) + \sin^2(\vartheta)}{\cos^2(\vartheta)}\right) \Rightarrow \\ &\Rightarrow Y = \frac{U_1^2}{\cos^2(\vartheta)} \Rightarrow \cos(\vartheta)\sqrt{Y} = U_1 \end{aligned} \quad (24)$$

Finalmente, substituindo 24 em 23, obtemos:

$$U_2 = \tan(\vartheta) \cos(\vartheta)\sqrt{Y} = \sin(\vartheta)\sqrt{Y} \quad (25)$$

Dos resultados 24 e 25, definimos T^{-1} como:

$$T^{-1}(y, \vartheta) = \left(\cos(\vartheta)\sqrt{Y}, \sin(\vartheta)\sqrt{Y}\right)$$

A partir deste ponto, estamos prontos para encontrar a PDF conjunta de Y e ϑ pelo método da transformação.

$$f_{Y,\vartheta}(y, \theta) = f_{U_1, U_2}(T^{-1}(y, \theta)) |det(\mathcal{J}_{T^{-1}})| \quad (26)$$

Onde $\mathcal{J}_{T^{-1}}$ denota a matriz Jacobiana de T^{-1} . Assim,

$$\begin{aligned} |det(\mathcal{J}_{T^{-1}})| &= \left| \det \left(\frac{\partial(U_1, U_2)}{\partial(Y, \vartheta)} \right) \right| = \left| \det \left(\begin{array}{cc} \frac{\partial U_1}{\partial Y} & \frac{\partial U_1}{\partial \vartheta} \\ \frac{\partial U_2}{\partial Y} & \frac{\partial U_2}{\partial \vartheta} \end{array} \right) \right| = \left| \det \left(\begin{array}{cc} \frac{\cos \vartheta}{2\sqrt{Y}} & -\sqrt{Y} \sin \vartheta \\ \frac{\sin \vartheta}{2\sqrt{Y}} & \sqrt{Y} \cos \vartheta \end{array} \right) \right| \Rightarrow \\ \Rightarrow |det(\mathcal{J}_{T^{-1}})| &= \left| \frac{\cos \vartheta}{2\sqrt{Y}} \sqrt{Y} \cos(\vartheta) + \frac{\sin(\vartheta)}{2\sqrt{Y}} \sqrt{Y} \sin(\vartheta) \right| = \frac{1}{2}. \end{aligned} \quad (27)$$

Portanto,

$$f_{Y,\vartheta}(y, \theta) = f_{U_1, U_2}(T^{-1}(y, \theta)) \cdot \frac{1}{2} = f_{U_1, U_2}(\cos(\vartheta)\sqrt{Y}, \sin(\vartheta)\sqrt{Y}) \cdot \frac{1}{2} = \mathbb{1}_{y \in [0,1]} \frac{\mathbb{1}_{\theta \in [0,2\pi]}}{2\pi} \quad (28)$$

Uma vez que $\mathbb{1}_{y \in [0,1]}$ é a PDF da $\mathcal{U}_{[0,1]}$ e $\frac{\mathbb{1}_{\theta \in [0,2\pi]}}{\pi}$ é a PDF da $\mathcal{U}_{[-\frac{\pi}{2}, \frac{\pi}{2}]}$, dado que a função $\arctan(\vartheta)$ tem como imagem o conjunto $[-\frac{\pi}{2}, \frac{\pi}{2}]$.

2. Show that X_1 and X_2 are independent standard normal random variables.

Solução:

Do item 1, usamos o resultado de que $Y \sim \mathcal{U}_{[0,1]}$. Isso é facilmente verificável:

Dado que $Y = U_1^2 + U_2^2 \leq 1$,

$$P(Y \leq t) = P(U_1^2 + U_2^2 \leq t) = \frac{\pi \sqrt{t}^2}{\pi \sqrt{1}^2} = t \quad (29)$$

Como $P(Y \leq t)$ é a CDF de Y , deduzimos daí que $Y \sim \mathcal{U}_{[0,1]}$. Seguindo em frente, defina $Z = \sqrt{-2 \log Y}$. Assim, $Y = e^{-\frac{Z^2}{2}}$. Pelo **Teorema fundamental da simulação** (enunciado na [questão 1](#)), temos que $Y \sim \mathcal{U}_{[0,1]}$ e $Z^2 = F^{-1}(Y) \Rightarrow Z^2 \sim F$, onde $F = \exp(1/2)$, i.e., concluímos que $Z^2 \sim \exp(1/2)$.

Como Z^2 e ϑ são independentes, com $\vartheta \sim \mathcal{U}_{[0,2\pi]}$, temos que

$$f_{Z^2, \vartheta}(z^2, \theta) = f_{Z^2}(z^2) \cdot f_{\vartheta}(\theta) = \frac{1}{2} \exp\left(-\frac{1}{2}z^2\right) \cdot \frac{1}{2\pi} \quad (30)$$

Aplicando uma transformação de variáveis,

$$f_{(X_1, X_2)}(x_1, x_2) = f_{(Z^2, \vartheta)}(z^2, \theta) \left| \det \left(\frac{\partial(Z^2, \vartheta)}{\partial(X_1, X_2)} \right) \right| \quad (31)$$

Onde,

$$\begin{aligned} \left| \det \left(\frac{\partial(Z^2, \vartheta)}{\partial(X_1, X_2)} \right) \right|^{-1} &= \left| \det \left(\begin{array}{cc} \frac{\partial X_1}{\partial Z^2} & \frac{\partial X_1}{\partial \vartheta} \\ \frac{\partial X_2}{\partial Z^2} & \frac{\partial X_2}{\partial \vartheta} \end{array} \right) \right|^{-1} = \left| \det \left(\begin{array}{cc} \frac{\cos \vartheta}{2Z} & -Z \sin \vartheta \\ \frac{\sin \vartheta}{2Z} & Z \cos \vartheta \end{array} \right) \right|^{-1} = \\ &= \left| \frac{\cos \vartheta Z \cos \vartheta}{2Z} + \frac{\sin \vartheta Z \sin \vartheta}{2Z} \right|^{-1} = \left| \frac{\cos^2 \vartheta + \sin^2 \vartheta}{2} \right|^{-1} = 2 \end{aligned} \quad (32)$$

Assim, substituindo o resultado 32 em 31, temos:

$$\begin{aligned} f_{(X_1, X_2)}(x_1, x_2) &= \frac{1}{2\pi} \exp\left(-\frac{1}{2}z^2\right) = \frac{1}{2\pi} \exp\left(-\frac{1}{2}(X_1^2 + X_2^2)\right) = \\ &= \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{X_1^2}{2}\right) + \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{X_2^2}{2}\right) = f_{X_1}(x_1) \cdot f_{X_2}(x_2) \end{aligned} \quad (33)$$

Portanto, concluímos que X_1 e X_2 são independentes, e seguem uma distribuição normal padrão.

3. What are the potential benefits of this approach over the Box-Muller algorithm?

Solução:

Diferentemente da abordagem de Box-Muller, o método Polar de Marsaglia tem a vantagem de substituir o cálculo de funções trigonométricas (seno e cosseno) por pontos, i.e., coordenadas U_1 e U_2 normalizadas pelo raio da circunferência ($\sqrt{U_1^2 + U_2^2}$).

No caso anterior, quando tomamos um ponto aleatório (U_1, U_2) , vimos que esse ponto, pelo método de Marsaglia, será projetado no ponto $(X_1, X_2) = \left(Z \frac{U_1}{\sqrt{Y}}, Z \frac{U_2}{\sqrt{Y}}\right)$, cujo cálculo das coordenadas é computacionalmente menos custoso do que o proposto pelo método de Box-Muller, cujas coordenadas seriam $(\bar{X}_1, \bar{X}_2) = (Z \cos(\vartheta), Z \sin(\vartheta))$.

Em outras palavras, o algoritmo polar de Marsaglia tem um menor custo computacional.

Exercise 4 (Transformation)

1. Let $\pi(x) = \tilde{\pi}(x)/Z_\pi$ be any probability function on \mathbb{R} . Prove that if (U, V) is uniformly distributed on $G = \{(u, v); 0 \leq u \leq \sqrt{\tilde{\pi}(v/u)}\}$, then V/U is distributed according to π , i.e., admits π as a probability density function.

Solução:

Tome a transformação $T(u, v) = (u, v/u) = (x_1, x_2)$. É fácil notar que T é inversível. Assim, podemos aplicar a fórmula da transformação de variáveis (que já foi apresentada no exercício anterior), obtendo:

$$f_{X_1, X_2}(x_1, x_2) = f_{U, V}(x_1, x_2) |\det \mathcal{J}_T| \quad (34)$$

Onde \mathcal{J}_T é o Jacobiano da inversa da função T . Então,

$$|\det \mathcal{J}_T|^{-1} = \left| \det \frac{\partial(x_1, x_2)}{\partial(u, v)} \right|^{-1} = \left| \det \begin{pmatrix} 1 & 0 \\ -v/u^2 & 1/u \end{pmatrix} \right|^{-1} = u = x_1 \quad (35)$$

Portanto, fazendo a devida substituição em 34,

$$f_{X_1, X_2}(x_1, x_2) = \mathbb{1}_{\{(x_1, x_2): 0 \leq x_1 \leq \sqrt{\tilde{\pi}(x_2)}\}} \cdot x_1 \quad (36)$$

Não obstante,

$$\begin{aligned} f_{X_2}(x_2) &= \int_0^{\sqrt{\tilde{\pi}(x_2)}} f_{X_1, X_2}(x_1, x_2) dx_1 = \int_0^{\sqrt{\tilde{\pi}(x_2)}} \mathbb{1}_{\{(x_1, x_2): 0 \leq x_1 \leq \sqrt{\tilde{\pi}(x_2)}\}} \cdot x_1 dx_1 = \\ &= \int_0^{\sqrt{\tilde{\pi}(x_2)}} x_1 dx_1 = \frac{\tilde{\pi}(x_2)}{2} = \pi(x_2) \end{aligned}$$

Com isso, mostramos que

$$f_{V/U}(v/u) = \pi(v/u)$$

□

2. In order to use the result of (1) in practice, we need to be able to sample uniformly from G . Show that if $\sup_x \sqrt{\tilde{\pi}(x)} < \infty$ and $\sup_x |x| \sqrt{\tilde{\pi}(x)} < \infty$, then $G \subseteq R$, where

$$R = \left[0, \sup_x \sqrt{\tilde{\pi}(x)} \right] \times \left[\inf_x x \sqrt{\tilde{\pi}(x)}, \sup_x x \sqrt{\tilde{\pi}(x)} \right].$$

Suggest a way to sample uniformly from G .

Solução:

Considere a dupla $(u, v) \in G$, e $v/u \in \pi$, $u \neq 0$. Assim, é fácil ver que

$$0 \leq u \leq \sqrt{\tilde{\pi}(v/u)} \Rightarrow 0 \leq u \leq \sup_x \sqrt{\tilde{\pi}(v/u)} \quad (37)$$

Logo, $v/u \in \mathbb{R}$ e $u \in (0, \sqrt{\tilde{\pi}(v/u)})$.

Revisitando a desigualdade em 37, podemos usar o seguinte truque:

$$\begin{aligned}
0 \leq u = \frac{v}{v/u} \leq \sqrt{\tilde{\pi}(v/u)} &\Rightarrow 0 \leq u = \frac{v}{v/u} \leq \sqrt{\tilde{\pi}(v/u)} \Rightarrow \\
-\frac{v}{u} \sqrt{\tilde{\pi}(v/u)} \leq v \leq \frac{v}{u} \sqrt{\tilde{\pi}(v/u)} &\Rightarrow \inf_{v/u} \frac{v}{u} \sqrt{\tilde{\pi}(v/u)} \leq v \leq \sup_{v/u} \frac{v}{u} \sqrt{\tilde{\pi}(v/u)}
\end{aligned} \tag{38}$$

Portanto, $v \in \left[-\inf_{v/u} \frac{v}{u} \sqrt{\tilde{\pi}(v/u)}, \sup_{v/u} \frac{v}{u} \sqrt{\tilde{\pi}(v/u)} \right]$. Com isso, concluímos que $(u, v) \in G \Rightarrow (u, v) \in R$. Logo, $G \subseteq R$.

Como $G \subseteq R$, podemos amostrar uniformemente de G usando um algoritmo de *Rejection Sampling* de uma Uniforme.

3. Let $\tilde{\pi}(x) = \exp(-x^2/2)$. Using results from (1) and (2), propose a method to sample from $\pi(x)$.

Solução:

Aplicando os resultados do item (2) para o caso em que $\tilde{\pi}(x) = \exp(-x^2/2)$, temos que:

$$\sup_{v/u} \sqrt{\tilde{\pi}(v/u)} = 1, \quad \inf_{v/u} \frac{v}{u} \sqrt{\tilde{\pi}(v/u)} = -\sqrt{2/e}, \quad \sup_{v/u} \frac{v}{u} \sqrt{\tilde{\pi}(v/u)} = \sqrt{2/e}.$$

Assim,

$$R = [0, 1] \times [-\sqrt{2/e}, \sqrt{2/e}]$$

Ainda, note que:

$$u \leq \sqrt{\tilde{\pi}(v/u)} \Leftrightarrow u^2 \leq \tilde{\pi}(v/u) \Leftrightarrow u^2 \leq \exp(-x^2/2)$$

Onde $x = v/u$. Portanto,

$$u^2 \leq \exp(-x^2/2) \Leftrightarrow 2 \log u \leq \frac{-x^2}{2} \Leftrightarrow 4 \log u \leq -\frac{v^2}{u^2} \Leftrightarrow v^2 \leq -4u^2 \log u.$$

Um possível algoritmo para amostrar de $\pi(x)$ é:

1. Gerar $U \sim \mathcal{U}_{[0,1]}$ e $V \sim \mathcal{U}_{[-\sqrt{2/e}, \sqrt{2/e}]}$ independentes até que $V^2 \leq -4U^2 \log U$
2. Armazenar $\frac{V}{U}$.

Ao fim do processo, teremos uma amostra $X_i = \frac{V_i}{U_i} \sim \exp(-x^2/2)$.

Exercise 5 (Rejection and Importance Sampling)

Consider two probability densities π, q on \mathbb{X} such that $\pi(x) > 0 \Rightarrow q(x) > 0$ and assume that you can easily draw samples from q . Whenever $\pi(x)/q(x) \leq M < \infty$ for any $x \in \mathbb{X}$, it is possible to use rejection sampling to sample from π . When M is unknown or when this condition is not satisfied, we can use importance sampling techniques to approximate expectations with respect to π . However it might be the case that most samples from q have very small importance weights.

Rejection control is a method combining rejection and importance weighting. It relies on an arbitrary threshold value $c > 0$. We introduce the notation $w(x) = \pi(x)/q(x)$ and

$$Z_c = \int_{\mathbb{X}} \min\{1, w(x)/c\} q(x) dx$$

Rejection control proceeds as follows.

- **Step a.** Generate independent $X \sim q, U \sim \mathcal{U}_{[0,1]}$ until $U \leq \min\{1, w(x)/c\}$
- **Step b.** Return X .

1. Give the expression of the probability density $q^*(x)$ of the accepted samples.

Solução:

Como já foi visto nos exercícios anteriores,

$$P(X \in A \mid X \text{ aceito}) = \frac{P(X \in A, X \text{ aceito})}{P(X \text{ aceito})} \quad (39)$$

Assim,

$$P(X \in A, X \text{ aceito}) = \int_A \int_0^1 \mathbb{1}_{\{u \in (0, \min\{1, w(x)/c\})\}} q(x) du dx = \int_A \min\{1, w(x)/c\} q(x) dx \quad (40)$$

e

$$P(X \text{ aceito}) = \int_{\mathbb{X}} \int_0^1 \mathbb{1}_{\{u \in (0, \min\{1, w(x)/c\})\}} dx = \int_{\mathbb{X}} \min\{1, w(x)/c\} q(x) dx \quad (41)$$

Substituindo 40 e 41 em 39:

$$P(X \in A \mid X \text{ aceito}) = \frac{\int_A \min\{1, w(x)/c\} q(x) dx}{\int_{\mathbb{X}} \min\{1, w(x)/c\} q(x) dx} = \frac{\int_A \min\{1, w(x)/c\} q(x) dx}{Z_c} \quad (42)$$

Portanto,

$$q^*(x) = \frac{\min\{1, w(x)/c\} q(x)}{Z_c} \quad (43)$$

2. Prove that

$$\mathbb{E}_{q^*}([w^*(X)]^2) = Z_c \mathbb{E}_q(\max\{w(X), c\} w(X))$$

where $w^*(x) = \pi(x)/q^*(x)$.

Solução:

Do exercício anterior,

$$q^*(x) = \frac{\min\{1, w(x)/c\} q(x)}{Z_c}.$$

Com isso, inferimos que

$$\frac{\pi(x)}{q^*(x)} = \frac{\pi(x) Z_c}{\min\{1, w(x)/c\} q(x)} = \frac{w(x) Z_c}{\min\{1, w(x)/c\}}, \quad (44)$$

Uma vez que $\frac{1}{\min\{1, w(x)/c\}} = \max\{1, c/w(x)\}$, podemos reescrever 44 como:

$$\frac{\pi(x)}{q^*(x)} = \frac{w(x) Z_c}{\min\{1, w(x)/c\}} = w(x) Z_c \max\{1, c/w(x)\} = Z_c \max\{w(x), c\} \quad (45)$$

Com isso, podemos facilmente calcular a esperança:

$$\begin{aligned} E_{q^*(x)}([w^*(X)]^2) &= \int_{\mathbb{X}} \frac{\pi^2(x)}{q^{*2}(x)} q(x) dx = \int_{\mathbb{X}} \frac{\pi(x)}{q^*(x)} \pi(x) dx = Z_c \int_{\mathbb{X}} \max\{w(x), c\} \pi(x) dx = \\ &= Z_c \int_{\mathbb{X}} \max\{w(x), c\} w(x) q(x) dx = Z_c \mathbb{E}_{q(x)}(\max\{w(X), c\} w(X)) \end{aligned} \quad (46)$$

□

3. Establish that

$$\mathbb{E}_q(\min\{w(X), c\}) \mathbb{E}_q(\max\{w(X), c\} w(X)) \leq \mathbb{E}_q(\min\{w(X), c\} \max\{w(X), c\} w(X))$$

(Hint. Show first that for any $c > 0$, $w_1 > 0$, $w_2 > 0$

$$h(w_1, w_2) = [\min\{w_1, c\} - \min\{w_2, c\}] [w_1 \max\{w_1, c\} - w_2 \max\{w_2, c\}] \geq 0$$

This is related to the Harris inequality).

Solução:

(Não consegui fazer)

4. Deduce from the results established in (2) and (3) that

$$\mathbb{V}_{q^*}(w^*(X)) \leq \mathbb{V}_q(w(X))$$

Solução:

(Não consegui fazer)

Exercise 6 (Rejection and Importance Sampling)

We want to use Monte Carlo methods to approximate the integral

$$I = \int_{\mathbb{X}} \phi(x) \pi(x) dx$$

where $\phi : \mathbb{X} \rightarrow \mathbb{R}$ and π is a probability density on \mathbb{X} . Assume we have access to a proposal probability density q such that $w(x) = \pi(x)/q(x) \leq M < \infty$ for any $x \in \mathbb{X}$.

1. Consider the extended probability density

$$\bar{\pi}_{X,U}(x, u) = \begin{cases} Mq(x) & \text{for } x \in \mathbb{X}, u \in \left[0, \frac{w(x)}{M}\right] \\ 0 & \text{otherwise} \end{cases}$$

Verify that $\bar{\pi}_X(x) = \pi(x)$.

Solução:

Ora,

$$\bar{\pi}_X(x) = \int_0^1 \bar{\pi}_{X,U}(x, u) du = \int_0^{w(x)/M} Mq(x) du = M[q(x)u]_0^{w(x)/M} = w(x)q(x) = \pi(x) \quad (47)$$

2. Using the identity

$$I = \int_0^1 \int_{\mathbb{X}} \phi(x) \bar{\pi}_{X,U}(x, u) dx du,$$

give the expression of the normalised importance sampling estimate \hat{I}_n of I when using n independent samples (X_i, U_i) such that $(X_i, U_i) \sim \bar{q}_{X,U}$, where $\bar{q}_{X,U}(x, u) = q(x) \times \mathbb{I}_{[0,1]}(u)$ (that is under $\bar{q}_{X,U}$ we have $X \sim q$, $U \sim \mathcal{U}_{[0,1]}$ and X and U are independent). Express this estimate as a function the importance weight function

$$\bar{w}(x, u) = \frac{\bar{\pi}_{X,U}(x, u)}{\bar{q}_{X,U}(x, u)}$$

Show that this estimate is equivalent to the estimate one would obtain by sampling from π using rejection sampling using n proposals from q .

Solução:

Primeiramente, vamos calcular $\bar{w}_{X,U}(x, u)$:

$$\bar{w}_{X,U}(x, u) = \frac{\bar{\pi}_{X,U}(x, u)}{\bar{q}_{X,U}(x, u)} = \begin{cases} \frac{Mq(x)}{q(x)} = M, & \text{se } x \in \left[0, \frac{w(x)}{M}\right] \\ 0, & \text{caso contrário} \end{cases} \quad (48)$$

Agora, podemos fazer uma aproximação de Monte Carlo \hat{I} para I , considerando n amostras independentes (X_i, U_i) , por meio da seguinte relação:

$$\hat{I}_n = \frac{\sum_{i=1}^n \phi(X_i) \bar{w}(X_i, U_i)}{\sum_{i=1}^n \bar{w}(X_i, U_i)} = \frac{M \sum_{i=1}^d \phi(X_i)}{d \cdot M} = \frac{\sum_{i=1}^d \phi(X_i)}{d} \quad (49)$$

Onde d representa o número de pesos \bar{w} diferentes de 0.

Equivalentemente, poderíamos obter uma estimativa para I por meio de um algoritmo de *Rejection Sampling*, tomando a $\bar{q}_{X,U}(x, u)$ como distribuição proposta, e $\bar{\pi}_{X,U}(x, u)$ como distribuição *target*.

3. Show that

$$\mathbb{V}_q(w(X)) \leq \mathbb{V}_{\bar{q}_{X,U}}(\bar{w}(X, U)).$$

Solução:

(Nao consegui fazer)

4. Show similarly that one can reinterpret the rejection control control procedure introduced in Exercise 5 as a standard importance sampling procedure on the extended space $\mathbb{X} \times [0, 1]$. Give the expressions of the extended "target" probability density $\tilde{\pi}_{X,U}$ on $\mathbb{X} \times [0, 1]$, the associated importance density $\tilde{q}_{X,U}(x, u)$ and show that

$$\mathbb{V}_q(w(X)) \leq \mathbb{V}_{\tilde{q}_{X,U}}(\tilde{w}(X, U))$$

where $\tilde{w}(x, u) = \tilde{\pi}_{X,U}(x, u)/\tilde{q}_{X,U}(x, u)$.

Solução:

(Não consegui fazer)

Simulation question (Rejection)

1. Reproduce the figures on the estimation of the number π in the slides of Lecture 2.

Solução:

Considere um quadrado $Q \subset \mathbb{R}^2$, cujos lados têm tamanho 1. Por simplificação, suponha $Q = [0, 1] \times [0, 1]$. Agora, tome um círculo C , inscrito no quadrado, com raio $\frac{1}{2}$. Suponha que estamos interessados em calcular a área do círculo A_C .

$$A_C = \pi \left(\frac{1}{2}\right)^2 = \frac{\pi}{4} = \int \int_C dx dy = \int \int_Q \mathbb{1}_{\{(x,y) \in C\}} dx dy \Rightarrow \pi = 4 \int_Q \mathbb{1}_{\{(x,y) \in C\}} dx dy \quad (50)$$

Sabemos que a área do quadrado $A_Q = 1$. Então,

$$\frac{A_C}{A_Q} \iff \frac{\pi}{4} \Rightarrow A_C = 4A_Q \quad (51)$$

Para aproximar o valor dessa integral, vamos utilizar Monte Carlo. Se gerarmos um número grande o suficiente de pontos, temos:

$$\frac{A_C}{A_Q} = \frac{\eta_C}{\eta} = \frac{\pi}{4} \Rightarrow \pi = 4 \frac{\eta_C}{\eta} \quad (52)$$

Onde η_C é o número de pontos dentro do círculo, e η é o total de pontos dentro do quadrado. Por meio da relação em 52, vamos estimar π utilizando o seguinte algoritmo:

1. Geramos $X, Y \sim \mathcal{U}_{[0,1]}$
2. Se $X^2 + Y^2 \leq 1$, adicionamos 1 a η_C e η . Caso contrário, adicionamos 1 apenas a η .
3. Executamos novamente a partir do passo (1).
4. Após atingirmos o tamanho da amostra desejado, estimamos π pela relação 52.

Abaixo, é apresentado o código para execução em Python e, a seguir, o resultado da estimativa de Monte Carlo para π .

```

1 # imports
2 import numpy as np
3
4 n = 100      # tamanho da amostra
5 l = 1       # lado do quadrado
6 r = 1/2     # raio do círculo
7 Nc = 0      # Numero de pontos dentro do círculo
8 inside = [] # armazena um booleano (True se o ponto esta dentro do círculo)
9
10 # gerando n numeros aleatorios X e Y
11 x = np.random.rand(n)
12 y = np.random.rand(n)
13
14 # Conta o numero de pontos dentro do círculo.
15 for x_i, y_i in zip(x, y):
16
17     # checa se o ponto (X,Y) esta dentro do círculo
18     if x_i**2 + y_i**2 <= 1.0:
19         Nc += 1
20         inside.append(True)

```



```

21     else:
22         inside.append(False)
23
24 pi = (float(Nc) / n) * 4      # Nc / Np = pi / 4
25 print('Estimativa de Monte Carlo para pi:', pi)

```

Após realizar esse experimento 1000 vezes (com um tamanho de amostra fixo em 10 mil), a estimativa média para π foi de 3.1406.




Figura 1: $X, Y \sim \mathcal{U}_{[0,1]}$. De laranja se $X^2 + Y^2 \leq 1$.

2. Implement the Box-Muller algorithm from Lecture 2.

Solução:

Vamos implementar o algoritmo de Box-Muller da Aula 2 com o seguinte código:

```

1 # imports
2 import numpy as np
3
4 def BoxMuller(n):
5     # geramos variaveis em pares
6     n_pares = int(np.ceil(n/2))
7
8     R = np.sqrt(-2 * np.log(np.random.ranf(n_pares))) # simulando R
9     theta = np.pi * 2 * np.random.ranf(n_pares)     # simulando theta
10
11     X_1 = R * np.cos(theta) # amostra x_1
12     X_2 = R * np.sin(theta) # amostra x_2
13
14     return X_1, X_2
15
16 n = 10000
17 x_1, x_2 = BoxMuller(n*2)

```

Agora, vamos plotar X_1 e X_2 e comparar suas densidades com as de duas normais padrão "genuínas".




Figura 2: X_1 e X_2 geradas a partir do algoritmo de Box-Muller

Aparentemente, X_1 e X_2 têm densidades bem próximas à de uma normal padrão. Com o próximo gráfico (3), também vemos que X_1 e X_2 mostram, a princípio, ser independentes (conforme já esperávamos como resultado do algoritmo de Box-Muller).




Figura 3: Distribuição conjunta de X_1 e X_2 .

3. Consider the genetic linkage model as in the slides of Lecture 3. Sample some simulated data with a fixed value of θ of your choice. Implement rejection sampling and reproduce the histograms of the posterior of θ and the waiting time before acceptance. Experiment with different proposal distributions.

Solução:

Recorrendo ao modelo *Genetic Linkage* apresentado na Nota de Aula 2, temos a seguinte estrutura:

- Observamos $(Y_1, Y_2, Y_3, Y_4) \sim \mathcal{M}(n; \frac{1}{2} + \frac{\theta}{4}; \frac{1}{4}(1 - \theta); \frac{\theta}{4})$, onde \mathcal{M} é uma distribuição multinomial e $\theta \in (0, 1)$.
- A verossimilhança é dada por

$$p(y_1, \dots, y_4 | \theta) \propto (2 + \theta)^{y_1} (1 - \theta)^{y_2 + y_3} \theta^{y_4}$$

- Seguindo a abordagem Bayesiana com *priori* $p(\theta) = \mathbb{I}_{\{\theta \in [0,1]\}}$, temos como *posteriori*:

$$p(\theta | y_1, \dots, y_4) \propto (2 + \theta)^{y_1} (1 - \theta)^{y_2 + y_3} \theta^{y_4}$$

Com isso em mente, vamos aplicar *Rejection Sampling* tomando $q(\theta) = \tilde{q}(\theta) = p(\theta)$ como distribuição proposta para amostrar de $p(\theta | y_1, \dots, y_4)$. Tomaremos como distribuição alvo

$$\tilde{\pi}(\theta) = (2 + \theta)^{y_1} (1 - \theta)^{y_2 + y_3} \theta^{y_4}$$

e $\tilde{M} = \sup_{\theta \in [0,1]} \tilde{\pi}(\theta)$, tal que $\sup_x \tilde{\pi}(x)/\tilde{q}(x) \leq \tilde{M}$.

Abaixo, segue o código da implementação do *Rejection Sampling*.

```

1 theta_verdadeiro = 0.7
2
3 # definindo funcao que retorna as probabilidades da multinomial
4 def pMultinomial(theta):
5     return [1/2 + theta/4, (1/4) * (1 - theta), (1/4) * (1 - theta), theta/4]
6
7 def logVerossimilhanca(theta):
8     # np.random.seed(17)
9     # amostrando de uma multinomial
10    sample = np.random.multinomial(100, pMultinomial(theta_verdadeiro), size=1)
11    sample = sample[0]
12
13    return sample[0]*np.log(2+theta) + (sample[1]+sample[2])*np.log(1 - theta) +
14    sample[3]*np.log(theta)
15
16 # avalia a log verossimilhanca em um grid
17 grid = np.linspace(0,1,10000)
18 ver = list(map(logVerossimilhanca, grid[1:]))
19
20 max_ver = max(ver) # m x . verossimilhanca
21
22 # encontra o estimador de maxima verossimilhanca
23 max_theta = 0
24 for i in range(len(ver)):
25     if ver[i] == max_ver:
26         max_theta = grid[i]
27
28 print('Maximum Likelihood Estimation:', max_theta)

```

```

29 # Aplicando rejection sampling
30
31 N = 10000                                # numero de pontos que queremos amostrar
32 n_aceito = 0                             # numero de pontos que foram aceitos
33 amostras = []                            # pontos amostrados
34 total_amostras = 0                       # total de pontos que foram amostrados
35 n_amostras_ac = np.repeat(0,N)          # numero de pontos amostrados ate a aceitacao
36
37 while n_aceito < N:
38     total_amostras += 1
39     n_amostras_ac[n_aceito] = n_amostras_ac[n_aceito] + 1
40     x = np.random.rand(1)[0]
41     log_alfa = logVerossimilhanca(x) - max_ver
42
43     if np.log(np.random.rand(1)[0]) < log_alfa:
44         n_aceito += 1
45         amostras.append(x)
46
47 print('Numero de amostras aceitas:', n_aceito)
48 print('Total de amostras retiradas:', total_amostras)

```

Abaixo, temos os gráficos da distribuição da amostra que compomos e a distribuição do número de tentativas até a aceitação de cada ponto sorteado, respectivamente.




Figura 4: Distribuição *target* | Tempo de aceitação




Figura 5: Tempo de aceitação

4. Implement a sampler to draw from a mixture of Gaussians

$$\pi(x) = \omega_1 \phi(x; \mu_1, \sigma_1^2) + \omega_2 \phi(x; \mu_2, \sigma_2^2),$$

where ϕ is the Gaussian pdf. You are allowed to use R's Gaussian generator (but feel free to reimplement Box-Muller from Lecture 3 or Marsaglia's method from Question 1 of this sheet, just for fun).

Solução:

Take $w_1 = 1 - w_2 \in [0, 1]$. Assim, vamos utilizar o seguinte código para amostrar de uma mistura de gaussianas:

```

1 # funcao para amostrar de uma mistura de 2 gaussianas
2 def mistura_2gaussianas(w1, mu1, sigma1, mu2, sigma2):
3     w2 = 1-w1
4     r = np.random.randint(0,2)
5     random_number = w1*r + w2*(1-r)
6
7     if random_number == w1:
8         a = np.random.normal(mu1, sigma1)
9     elif random_number == w2:
10        a = np.random.normal(mu2, sigma2)
11
12    return a
13
14 N = 10000          # tamanho da amostra
15 amostras = []     # pontos sorteados
16
17 # fazendo a amostragem
18 for i in range(N+1):
19     amostras.append(mistura_2gaussianas(0.41, 4.5, 1, 1.2, 1))

```




Figura 6: Histograma de $X \sim \pi(x)$, onde $w_1 = 0.41$, $w_2 = 0.59$, $\mu_1 = 4.5$, $\mu_2 = 1.2$, e $\sigma_1\sigma_2 = 1$

5. Let

$$h(x) = [\cos(50x) + \sin(20x)].$$

We consider estimating $\int_0^1 h(x)dx$ through Monte Carlo methods.

- First of all, what is the exact answer, to accuracy within 10^{-4} ?
- Can you implement rejection sampling with a uniform proposal?
- Find a way to assess how good you are doing.
- Implement an importance sampling solution with a smart proposal (*hint: plot h and find a matching q*).


Solução:

Primeiramente, vamos visualizar a função $h(x)$:

- Integrando $h(x)$, encontramos:

$$\begin{aligned} \int_0^1 h(x)dx &= \left[\frac{x}{2} + \frac{\sin(100x)}{200} + 2 \left(\frac{\cos(30x)}{60} - \frac{\cos(70x)}{140} \right) + \frac{x}{2} - \frac{\sin(40x)}{80} \right]_0^1 = \\ &= H(1) - H(0) = 0.9652009360501459 \end{aligned}$$

A seguir, é apresentado o código para implementação em Python.

Figura 7: $h(x) = \cos(50x) + \sin(20x)$

```

1 # define h(x)
2 def h(x):
3     return np.cos(50*x) + np.sin(20*x)
4
5 grid = np.linspace(0, np.pi/4, 1000) # grid para o plot
6 y = list(map(h, grid))               # avalia a funcao no grid
7
8 sns.lineplot(y=y, x=grid)            # faz o plot
9
10 # define a primitiva H(x)
11 def H(x):
12     return x/2 + np.sin(100*x)/200 + 2* (np.cos(30*x)/60 - np.cos(70*x)/140) + x
13     /2 - np.sin(40*x)/80
14
15 # calcula o verdadeiro valor da integral
16 integral = H(1) - H(0)
17 print('Valor verdadeiro da integral:', integral)

```

- Agora, vamos aplicar *Rejection Sampling* tomando uma distribuição uniforme em $[0, 1]$ como distribuição proposta. (Código abaixo)

```

1 N = 1000          # numero de pontos
2 Nrep = 1000       # numero de repeticoes
3 erros = []        # lista de erros
4
5 for i in range(Nrep):
6     u = np.random.rand()
7     w = h(u)
8     erros.append(np.abs(np.mean(w) - integral)/integral)

```

- (Não consegui implementar a tempo)




Figura 8: Erros de aproximação do valor verdadeiro da integral.

- (Não consegui implementar a tempo)