

Lista de Exercícios 2

Professor(a): Eduardo Mendes

Aluno: Franklin Alves de Oliveira

Exercise 1 (Monte Carlo for Gaussians)

1.

Conforme sugerido pelo enunciado, vamos calcular $\mathbb{E}_\pi[\phi(x)]$:

$$\mathbb{E}_\pi[\phi(x)] = \int_{\mathbb{X}} \phi(x) \pi(x) dx = \int_{\mathbb{X}} \phi(x) \frac{1}{(2\pi)^{d/2}} \exp \left\{ -\frac{1}{2} x^T x \right\} dx$$

Tomando $x = y + \theta$, temos:

$$\begin{aligned} \mathbb{E}_\pi[\phi(x)] &= \mathbb{E}_\pi[\phi(y + \theta)] = \int_{\mathbb{X}} \phi(y + \theta) \frac{1}{(2\pi)^{d/2}} \exp \left\{ -\frac{1}{2} (y + \theta)^T (y + \theta) \right\} dy = \\ &= \int_{\mathbb{X}} \phi(y + \theta) \frac{1}{(2\pi)^{d/2}} \exp \left\{ -\frac{1}{2} (y + \theta)^T (z + \theta) \right\} dy = \\ &= \int_{\mathbb{X}} \phi(y + \theta) \frac{1}{(2\pi)^{d/2}} \exp \left\{ -\frac{1}{2} (y^T y + 2\theta^T y + \theta^T \theta) \right\} dy = \\ &= \int_{\mathbb{X}} \phi(y + \theta) \frac{1}{(2\pi)^{d/2}} \exp \left\{ -\frac{1}{2} y^T y \right\} \exp \left\{ -\frac{1}{2} \theta^T \theta - \theta^T y \right\} dy = \\ &= \int_{\mathbb{X}} \phi(y + \theta) \pi(y) \exp \left\{ -\frac{1}{2} \theta^T \theta - \theta^T y \right\} dy = \\ &= \mathbb{E}_\pi \left[\phi(y + \theta) \exp \left\{ -\frac{1}{2} \theta^T \theta - \theta^T y \right\} \right] \end{aligned}$$

Fazendo uma troca de variáveis, i.e., $y = X$, temos:

$$\mathbb{E}_\pi[\phi(x)] = \mathbb{E}_\pi \left[\phi(X + \theta) \exp \left\{ -\frac{1}{2} \theta^T \theta - \theta^T X \right\} \right]$$

□

2.

Tomando a fórmula da variância, temos:

$$\sigma^2(\theta) = E_\pi [\phi^2(X + \theta) \exp \{-\theta^T \theta - 2\theta^T X\}] - E_\pi [\phi(x)]^2 \quad (1)$$

Note que:

$$E_\pi [\phi^2(x)] = E_\pi [\phi^2(X + \theta) \exp \{-\theta^T \theta - 2\theta^T X\}] =$$

$$\begin{aligned}
&= \int \phi^2(x + \theta) \frac{1}{(2\pi)^{d/2}} \exp \{-\theta^T \theta - 2\theta^T x\} \exp \left\{ -\frac{1}{2} x^T x \right\} dx = \\
&= \frac{1}{(2\pi)^{d/2}} \int \phi^2(x + \theta) \exp \{-\theta^T \theta - 2\theta^T x\} \exp \left\{ -\frac{1}{2} x^T x \right\} dx
\end{aligned} \tag{2}$$

Trocando a variável x por $y - \theta$, é fácil ver de 2 que:

$$\begin{aligned}
E_\pi [\phi(x)^2] &= \frac{1}{(2\pi)^{d/2}} \int \phi^2(y) \exp \{-\theta^T \theta - 2\theta^T (y - \theta)\} \exp \left\{ -\frac{1}{2} (y - \theta)^T (y - \theta) \right\} dy = \\
&= \frac{1}{(2\pi)^{d/2}} \int \phi^2(y) \exp \left\{ -\theta^T \theta - 2\theta^T (y - \theta) - \frac{1}{2} (y - \theta)^T (y - \theta) \right\} dy = \\
&= \frac{1}{(2\pi)^{d/2}} \int \phi^2(y) \exp \left\{ -\theta^T \theta - 2\theta^T (y - \theta) - \frac{1}{2} (y^T y + y^T \theta + \theta^T y - \theta^T \theta) \right\} dy = \\
&= \frac{1}{(2\pi)^{d/2}} \int \phi^2(y) \exp \left\{ -\theta^T \theta - 2\theta^T (y - \theta) - \frac{1}{2} y^T y + y^T \theta - \frac{1}{2} \theta^T \theta \right\} dy = \\
&= \frac{1}{(2\pi)^{d/2}} \int \phi^2(y) \exp \left\{ -\theta^T \theta - 2\theta^T y + 2\theta^T \theta - \frac{1}{2} y^T y + y^T \theta - \frac{1}{2} \theta^T \theta \right\} dy = \\
&= \frac{1}{(2\pi)^{d/2}} \int \phi^2(y) \exp \left\{ \frac{1}{2} \theta^T \theta - \theta^T y - \frac{1}{2} y^T y \right\} dy = \\
&= \frac{1}{(2\pi)^{d/2}} \int \phi^2(y) \exp \left\{ \frac{1}{2} \theta^T \theta - \theta^T y \right\} \exp \left\{ -\frac{1}{2} y^T y \right\} dy = \\
&= \mathbb{E} \left[\phi^2(X) \exp \left\{ \frac{1}{2} \theta^T \theta - \theta^T X \right\} \right],
\end{aligned} \tag{3}$$

Uma vez que $-\frac{1}{2} x^T x + \frac{1}{2} (x - \theta)^T (x - \theta) = \frac{1}{2} \theta^T \theta - \theta^T x$. Sendo assim, é fácil ver que

$$\mathbb{E}_\pi \left[\phi^2(X) \exp \left\{ -\frac{1}{2} X^T X + \frac{1}{2} (X - \theta)^T (X - \theta) \right\} \right] = \mathbb{E}_\pi \left[\phi^2(X) \exp \left\{ \frac{1}{2} \theta^T \theta - \theta^T X \right\} \right] \tag{4}$$

Substituindo 4 em 1:

$$\sigma^2(\theta) = \mathbb{E}_\pi \left[\phi^2(X) \exp \left\{ \frac{1}{2} \theta^T \theta - \theta^T X \right\} \right] - \mathbb{E}_\pi [\phi(x)]^2 \tag{5}$$

Como queríamos demonstrar. \square

3.

Do item 2, temos que

$$\sigma^2(\theta) = \mathbb{E}_\pi \left[\phi^2(X) \exp \left\{ -\frac{1}{2} X^T X + \frac{1}{2} (X - \theta)^T (X - \theta) \right\} \right] - \mathbb{E}_\pi [\phi(X)]^2 \tag{6}$$

Assim, derivando 6 em θ :

$$\begin{aligned}
\nabla \sigma^2(\theta) &= \nabla \mathbb{E}_\pi \left[\phi^2(X) \exp \left\{ -\frac{1}{2} X^T X + \frac{1}{2} (X - \theta)^T (X - \theta) \right\} \right] - \nabla \mathbb{E}_\pi [\phi(X)]^2 = \\
&= \nabla \mathbb{E}_\pi \left[\phi^2(X) \exp \left\{ -\frac{1}{2} X^T X + \frac{1}{2} (X - \theta)^T (X - \theta) \right\} \right] + 0 =
\end{aligned}$$

$$\mathbb{E}_\pi \left[\phi^2(X)(\theta - X) \exp \left\{ -\frac{1}{2}X^T X + \frac{1}{2}(X - \theta)^T(X - \theta) \right\} \right] \quad (7)$$

Agora, vamos derivar 7 para obter a derivada segunda de $\sigma^2(\theta)$. Como $\theta \in \mathbb{R}^d$, temos que tomar as derivadas componente a componente, i.e., calcular $\mathbb{H}_{i,j}(\theta) = \partial \sigma^2(\theta_i) / \partial \theta_j$, $\forall i, j \in \{1, \dots, d\}$ onde, por sua vez, $\mathbb{H}_{i,j}$ denota o elemento da i -ésima linha e j -ésima coluna da matriz Hessiana de σ^2 . Sendo assim, temos:

- (1) $\forall i \in \{1, \dots, d\}$, $\mathbb{H}_{i,i}(\theta) = \mathbb{E}_\pi \left[\phi^2(X) \exp \left\{ -\frac{1}{2}X^T X + \frac{1}{2}(X - \theta)^T(X - \theta) \right\} \right]$
- (2) $\forall i, j \in \{1, \dots, d\}, i \neq j$, $\mathbb{H}_{i,j}(\theta) = \mathbb{E}_\pi \left[\phi^2(X)(\theta_i - X)(\theta_j - X)^T \exp \left\{ -\frac{1}{2}X^T X + \frac{1}{2}(X - \theta)^T(X - \theta) \right\} \right]$

Não obstante, podemos escrever a matriz Hessiana como:

$$\begin{aligned} \mathbb{H}(\theta) &= \mathbb{I}_d \cdot \mathbb{E}_\pi \left[\phi^2(X) \exp \left\{ -\frac{1}{2}X^T X + \frac{1}{2}(X - \theta)^T(X - \theta) \right\} \right] + \\ &+ \mathbb{E}_\pi \left[\phi^2(X)(\theta_i - X)(\theta_j - X)^T \exp \left\{ -\frac{1}{2}X^T X + \frac{1}{2}(X - \theta)^T(X - \theta) \right\} \right] \end{aligned}$$

É fácil perceber que essa matriz é positiva semi-definida (todos os termos são estritamente positivos, pois são exponenciais ou quadrados). Isto é, se tomarmos um vetor não nulo u arbitrário tal que $u \in \mathbb{R}^d$, temos que $u^T \cdot \mathbb{H} \cdot u > 0$. O que prova que $\sigma^2(\theta)$ é estritamente convexa.

4.

No item anterior, mostramos que $\sigma^2(\theta)$ é estritamente convexa. A partir dessa informação, resta apenas encontrar o ponto crítico de $\sigma^2(\theta)$, i.e., encontrar um ponto θ^* tal que $\nabla \sigma^2(\theta^*) = 0$. Isto posto, usando o resultado do item 3,

$$\begin{aligned} \nabla \sigma^2(\theta) &= \mathbb{E}_\pi \left[\phi^2(X)(\theta - X) \exp \left\{ -\frac{1}{2}X^T X + \frac{1}{2}(X - \theta)^T(X - \theta) \right\} \right] = \\ &= \mathbb{E}_\pi \left[\phi^2(X)(\theta - X) \exp \left\{ -\frac{1}{2}X^T X + \frac{1}{2}(X^T X - X^T \theta - \theta^T X + \theta^T \theta) \right\} \right] = \\ &= \mathbb{E}_\pi \left[\phi^2(X)(\theta - X) \exp \left\{ \frac{1}{2}\theta^T \theta - X^T \theta \right\} \right] \end{aligned}$$

Rearranjando os termos, encontramos:

$$\nabla \sigma^2(\theta) = \exp \left\{ \frac{1}{2}\theta^T \theta \right\} \mathbb{E}_\pi \left[\phi^2(X)(\theta - X) \exp \left\{ -X^T \theta \right\} \right] \quad (8)$$

Como $\exp\{\theta^T \theta\} > 0$, $\forall \theta$, vale que:

$$\nabla \sigma^2(\theta^*) = 0 \iff \mathbb{E}_\pi \left[\phi^2(X)(\theta^* - X) \exp \left\{ -X^T \theta^* \right\} \right] = 0.$$

Temos, então, exatamente o resultado que desejamos.

5.

Dos item anterior, sabemos que

$$\nabla \sigma^2(\theta) = \exp \left\{ \frac{1}{2}\theta^T \theta \right\} \mathbb{E}_\pi \left[\phi^2(X)(\theta - X) \exp \left\{ -X^T \theta \right\} \right]$$

Convenientemente, vamos definir $\phi(x)$ da seguinte forma:

$$\phi(x) = \max \{0, \lambda \exp\{\sigma X\} - K\} \quad (9)$$

Podemos, ainda, reescrever $\nabla \sigma^2(\theta)$ para obter:

$$\nabla \sigma^2(\theta) = \exp \left\{ \frac{1}{2} \theta^T \theta \right\} \mathbb{E}_\pi [\theta \phi^2(X) \exp \{-\theta^T X\}] - \exp \left\{ \frac{1}{2} \theta^T \theta \right\} \mathbb{E}_\pi [X \phi^2(X) \exp \{-\theta^T X\}] \quad (10)$$

Se tomarmos os casos:

- (a) $\theta \leq 0 \Rightarrow \theta \cdot \mathbb{E}_\pi [\theta \phi^2(X) \exp \{-\theta^T X\}] \leq 0$ e $\mathbb{E}_\pi [X \phi^2(X) \exp \{-\theta^T X\}] > 0 \Rightarrow \nabla \sigma^2(\theta) < 0$.
- (b) Se $\theta \in (0, \sigma^{-1} \log(K/\lambda)) \Rightarrow X \geq \theta \Rightarrow \nabla \sigma^2(\theta) < 0$

Logo, para os dois casos, vemos que $\sigma^2(\theta)$ é decrescente.

Exercise 2 (Metropolis-Hastings)

1.

- (1) Amostramos X de $q(X_{t-1})$, i.e., $X \sim q(X_{t-1})$.
- (2) Amostramos $U \sim U[0, 1]$.
- (3) Se $U \leq \alpha(X_{t-1}, X)$ então tomamos $X_t := X$. Caso contrário, tomamos $X_{t-1} := X_t$.

2.

Ora,

$$\alpha(y, x) = \frac{\gamma(y, x)}{\pi(y)q(y, x)} \implies \alpha(y, x)\pi(y)q(y, x) = \gamma(y, x) \quad (11)$$

e

$$\alpha(x, y) = \frac{\gamma(x, y)}{\pi(x)q(x, y)} \implies \alpha(x, y)\pi(x)q(x, y) = \gamma(x, y) \quad (12)$$

Combinando 11 e 12, dado $\gamma(x, y) = \gamma(y, x)$, temos:

$$\alpha(x, y)\pi(x)q(x, y) = \alpha(y, x)\pi(y)q(y, x) \quad (13)$$

Exatamente como queríamos demonstrar.

3.

Tomando a probabilidade de aceitação do MCMC,

$$\begin{aligned} \alpha(x, y) &= \min \left\{ 1, \frac{\pi(y)q(y, x)}{\pi(x)q(x, y)} \right\} \iff \frac{\gamma(x, y)}{\pi(x)q(x, y)} = \min \left\{ 1, \frac{\pi(y)q(y, x)}{\pi(x)q(x, y)} \right\} \iff \\ &\iff \gamma(x, y) = \pi(x)q(x, y) \min \left\{ 1, \frac{\pi(y)q(y, x)}{\pi(x)q(x, y)} \right\} \iff \gamma(x, y) = \min \{ \pi(x)q(x, y), \pi(y)q(y, x) \} \end{aligned} \quad (14)$$

Com isso, é fácil ver que, ao aplicar o algoritmo MCMC, estamos, nesse caso, escolhendo valores convenientes para $\gamma(x, y)$.

4.

Temos $X^{\tau_k} = Y^t$, onde Y^t denota todas as propostas aceitas em um dado tempo t . No entanto, nem todo valor de Y é aceito. Logo, podemos denotar o tempo entre propostas aceitas por:

$$\tau_{k+1} - \tau_k \quad (15)$$

Assim, é fácil ver que

$$\frac{1}{\tau_k - 1} \sum_{j=1}^{k-1} (\tau_{j+1} - \tau_j) \cdot \phi(Y^j). \quad (16)$$

Como o *Kernel* é a probabilidade de, dado que estamos em um estado t , passarmos para $t + 1$, basta encontrarmos a probabilidade de aceitarmos um novo valor para Y , isto é, sairmos de Y^t para Y^{t+1} . Ora, isso equivale a aceitar um valor proveniente da distribuição $q(x, y)$. Sendo assim,

$$P(Y^{t+1} \text{ aceito} \mid Y^t \text{ aceito}) = \alpha(x, y) \cdot q(x, y) \quad (17)$$

Note que, não necessariamente, essa probabilidade integra 1. Para garantir isso, podemos normalizar os valores de 17 obtidos.

5.

Ora,

$$\tilde{\pi}(x)K(x, y) = \frac{\pi(x)m(x)}{\sum_{z \in X} \pi(z)m(z)} \frac{\alpha(x, y)q(x, y)}{m(x)} = \frac{\pi(x)\alpha(x, y)q(x, y)}{\sum_{z \in X} \pi(z)m(z)} \quad (18)$$

Se aplicarmos o resultado do item 3, obtemos:

$$\tilde{\pi}(x)K(x, y) = \frac{\pi(x)\alpha(x, y)q(x, y)}{\sum_{z \in X} \pi(z)m(z)} = \frac{\pi(y)\alpha(y, x)q(y, x)}{\sum_{z \in X} \pi(z)m(z)} \quad (19)$$

Multiplicando e dividindo por $m(y)$, chegamos a:

$$\tilde{\pi}(x)K(x, y) = \frac{\pi(x)\alpha(x, y)q(x, y)}{\sum_{z \in X} \pi(z)m(z)} \frac{m(y)}{m(y)} = \frac{\pi(y)\alpha(y, x)q(y, x)}{\sum_{z \in X} \pi(z)m(z)} \frac{m(y)}{m(y)} = \tilde{\pi}(y)K(y, x) \quad (20)$$

e, portanto, K é reversível em $\tilde{\pi}$.

6.

(Não consegui fazer)

Exercise 3 (Metropolis-Hastings)

1.

Ora,

$$\begin{aligned}
 \int_{\mathbb{X}} \pi(x) K(x, y) dx &= \int_{\mathbb{X}} \pi(x) [\alpha(x)q(y) + (1 - \alpha(x))\delta_x(y)] dx = \\
 &= \int_{\mathbb{X}} \pi(x)\alpha(x)q(y) dx + \int_{\mathbb{X}} (1 - \alpha(x))\delta_x(y) dx \propto \\
 &\propto q(y) \int_{\mathbb{X}} \frac{q(x)}{\alpha(x)} \alpha(x) dx + \int_{\mathbb{X}} (1 - \alpha(y)) \frac{q(y)}{\alpha(y)} dx \propto \\
 &\propto q(y) + (1 - \alpha(y)) \frac{q(y)}{\alpha(y)} \propto \pi(y)
 \end{aligned}$$

□

2.

Já sabemos que $\pi(x) \propto \frac{q(x)}{\alpha(x)}$. Assumindo que $0 \leq \alpha(x) = \alpha < 1$, temos que

$$\pi(x) \propto \frac{q(x)}{\alpha(x)} \propto q(x). \quad (21)$$

Adicionalmente, vamos assumir que $\mathbb{V}_q(X_1) = \sigma^2 < \infty$. Para calcularmos a variância assintótica, vamos primeiro determinar $\mathbb{Cov}(X_1, X_k)$. Assim,

$$\mathbb{Cov}(X_1, X_k) = \mathbb{E}[X_1 X_k] - \mathbb{E}[X_1]\mathbb{E}[X_k] \quad (22)$$

No regime estacionário, temos que $\mathbb{E}[X_1] = \mathbb{E}[X_k]$. Assim, prosseguindo com os cálculos em 22, temos:

$$\mathbb{Cov}(X_1, X_k) = \mathbb{E}[X_1 X_k \mid X_1, X_{k-1}] - \mathbb{E}[X_1]^2 \quad (23)$$

Note que $P(X_k = X_{k-1}) = 1 - \alpha$ e $P(X_k \sim q) = \alpha$. Com isso, podemos destacar que X_k é independente de X_1 e de X_{k-1} . Portanto, podemos reescrever a esperança condicional em 23 da seguinte forma:

$$\begin{aligned}
 \mathbb{Cov}(X_1, X_k) &= \mathbb{E}[X_1 X_k \mid X_1, X_{k-1}] - \mathbb{E}[X_1]^2 = (1 - \alpha)\mathbb{E}[X_1 X_{k-1}] + \alpha\mathbb{E}[X_1]\mathbb{E}[X_k] - \mathbb{E}[X_1]^2 = \\
 &= (1 - \alpha)\mathbb{E}[X_1 X_{k-1}] + \alpha\mathbb{E}[X_1]^2 - \mathbb{E}[X_1]^2 = (1 - \alpha)\mathbb{E}[X_1 X_{k-1}] - [(1 - \alpha)\mathbb{E}[X_1]^2] = \\
 &= (1 - \alpha) \mathbb{Cov}(X_1, X_{k-1}) = (1 - \alpha)^{k-1} \sigma^2
 \end{aligned} \quad (24)$$

Onde a última igualdade vem do fato que estamos supondo $\mathbb{V}_q(X_1) = \sigma^2$, e resolvendo recursivamente a equação para a covariância.

Agora estamos prontos para expressar a variância assintótica como:

$$\begin{aligned}
 \sigma_X^2 &= \mathbb{V}_q(X_1) + 2 \sum_{k=2}^{\infty} \mathbb{Cov}(X_1, X_k) = \sigma^2 + 2\sigma^2 \sum_{k=2}^{\infty} (1 - \alpha)^{k-1} = \sigma^2 \left[1 + 2 \sum_{k=2}^{\infty} (1 - \alpha)^{k-1} \right] = \\
 &= \sigma^2 \left[1 + \sum_{k=1}^{\infty} (1 - \alpha)^k \right] = \sigma^2 \left[\frac{2 - \alpha}{\alpha} \right]
 \end{aligned} \quad (25)$$

Assim fica fácil ver que

$$\lim_{\alpha \rightarrow 0} \sigma_X^2 = \lim_{\alpha \rightarrow 0} \sigma^2 \left[\frac{2 - \alpha}{\alpha} \right] = \infty. \quad (26)$$

Exercise 4 (Gibbs Sampler)

1.

Sabemos, trivialmente, que

$$\begin{aligned}\pi(x | y) &= \frac{\pi(x, y)}{\pi(y)} = \frac{\pi(x, y)}{\int \pi(x, y) dx} \propto \pi(x, y) \propto \exp \left\{ -\frac{1}{2}(x-1)^2(y-2)^2 \right\} = \\ &= \exp \left\{ \frac{-1}{2} \frac{(x-1)^2}{(y-2)^{-2}} \right\}\end{aligned}\quad (27)$$

Analogamente,

$$\begin{aligned}\pi(y | x) &= \frac{\pi(y, x)}{\pi(x)} = \frac{\pi(x, y)}{\int \pi(x, y) dy} \propto \pi(x, y) \propto \exp \left\{ -\frac{1}{2}(x-1)^2(y-2)^2 \right\} = \\ &= \exp \left\{ \frac{-1}{2} \frac{(y-2)^2}{(x-1)^{-2}} \right\}\end{aligned}\quad (28)$$

2.

Não. O Gibbs Sampler não faz sentido nesse caso, pois

$$\int \int \pi(x, y) dx dy = \int \int \exp \left\{ \frac{-1}{2} \frac{(x-1)^2}{(y-2)^{-2}} \right\} dx dy = \int \sqrt{2\pi(y-2)^{-2}} dy = +\infty, \quad (29)$$

isto é, $\pi(x, y)$ não é uma função de densidade de probabilidade pois não integra 1.

Exercise 5 (Gibbs Sampler)

1.

Considere duas v.a.'s independentes $X_i \sim \text{Binomial}(m_i, \theta_1)$ e $Y_i \sim \text{Binomial}(n_i, \theta_2)$, i.e.,

$$P(X_i = x_i) = \binom{m_i}{x_i} \theta_1^{x_i} (1 - \theta_1)^{m_i - x_i}$$

e

$$P(Y_i = y_i) = \binom{n_i}{y_i} \theta_2^{y_i} (1 - \theta_2)^{n_i - y_i}$$

Considerando, agora, uma terceira v.a. dada por $Z_i = X_i + Y_i$, temos

$$\begin{aligned}P(Z_i = z_i | \theta_1, \theta_2) &= P(X_i + Y_i = z_i | \theta_1, \theta_2) = \sum_{x_i=0}^{z_i} P(X_i = x_i | \theta_1) P(Y_i = z_i - x_i | \theta_2) = \\ &= \sum_{x_i=0}^{z_i} \binom{m_i}{x_i} \theta_1^{x_i} (1 - \theta_1)^{m_i - x_i} \binom{n_i}{z_i - x_i} \theta_2^{z_i - x_i} (1 - \theta_2)^{n_i - z_i + x_i}\end{aligned}\quad (30)$$

que é, de fato, a função verossimilhança para uma observação de Z_i . Tomando uma amostra *iid* $\{z_1, \dots, z_T\}$, temos:

$$P(z_1, \dots, z_T \mid \theta_1, \theta_2) = \prod_{i=1}^T \left[\sum_{x_i=0}^{z_i} \binom{m_i}{x_i} \theta_1^{x_i} (1 - \theta_1)^{m_i - x_i} \binom{n_i}{z_i - x_i} \theta_2^{z_i - x_i} (1 - \theta_2)^{n_i - z_i + x_i} \right] \quad (31)$$

2.

Assuma, inicialmente, $\vartheta_1, \vartheta_2 \sim \mathcal{U}_{[0,1]}$ e note que

$$\begin{aligned} P(\vartheta_1 = \theta_1 \mid X_1 = x_1, \dots, X_T = x_T, Y_1 = y_1, \dots, Y_T = y_T, Z_1 = z_1, \dots, Z_T = z_T) \\ = P(\vartheta_1 = \theta_1 \mid X_1 = x_1, \dots, X_T = x_T) \end{aligned} \quad (32)$$

Pois $X_i \perp\!\!\!\perp Y_i, \forall i = 1, \dots, T$; e, por sua vez,

$$P(\vartheta_1 = \theta_1 \mid X_1 = x_1, \dots, X_T = x_T) \propto P(X_1 = x_1, \dots, X_T = x_T \mid \theta_1) \cdot P(\theta_1) \quad (33)$$

Pela independência dos X_i 's, temos:

$$\begin{aligned} P(\vartheta_1 = \theta_1 \mid X_1 = x_1, \dots, X_T = x_T) &= P(X_1 = x_1 \mid \theta_1) \dots P(X_T = x_T \mid \theta_1) \cdot P(\theta_1) \propto \\ &\propto P(x_1 \mid \theta_1) \dots P(x_T \mid \theta_1), \end{aligned} \quad (34)$$

Dado que estamos assumindo $\vartheta_1 \sim \mathcal{U}_{[0,1]}$. Como cada um dos $X_i \sim \text{Binomial}(m_i, \theta_1)$, podemos reescrever 34 da seguinte forma:

$$P(\theta_1 \mid x_1, \dots, x_T) \propto P(x_1 \mid \theta_1) \dots P(x_T \mid \theta_1) = \binom{m_1}{x_1} \theta_1^{x_1} (1 - \theta_1)^{m_1 - x_1} \dots \binom{m_T}{x_T} \theta_1^{x_T} (1 - \theta_1)^{m_T - x_T}$$

Como estamos olhando para a distribuição dos θ 's (os x 's são realizações e, portanto, conhecidos), podemos escrever:

$$P(\theta_1 \mid x_1, \dots, x_T) \propto \prod_{j=1}^T \binom{m_i}{x_j} \theta_1^{x_j} (1 - \theta_1)^{m_i - x_j} \propto \prod_{j=1}^T \theta_1^{x_j} (1 - \theta_1)^{m_i - x_j} \quad (35)$$

Assim, podemos concluir que $\vartheta_1 \mid x_1, \dots, x_T \sim \text{Beta} \left(1 + \sum_{j=1}^T x_j, 1 + \sum_{j=1}^T (m_i - x_j) \right)$.

Por analogia, temos que $\vartheta_2 \mid x_1, \dots, x_T \sim \text{Beta} \left(1 + \sum_{j=1}^T y_j, 1 + \sum_{j=1}^T (n_i - y_j) \right)$.

Com isso, definimos completamente as probabilidades condicionais para ϑ_1 e ϑ_2 . Contudo, para aplicar o Gibbs Sampler, ainda precisamos ser capazes de amostrar de $P(x_i \mid y_1, \dots, y_T, z_1, \dots, z_T, \theta_1, \theta_2)$ e $P(y_i \mid X_1, \dots, x_T, z_1, \dots, z_T, \theta_1, \theta_2)$. Como $X_i \perp\!\!\!\perp Y_i$, isso equivale a amostrar de

$$P(X_1 = x_1, \dots, X_T = x_T, Y_1 = y_1, \dots, Y_T = y_T \mid Z_1 = z_1, \dots, Z_T = z_T, \vartheta_1 = \theta_1, \vartheta_2 = \theta_2)$$

Note que, saber $Z_i = z_i$ não nos diz muito sobre X_i e Y_i individualmente (saber a soma de X e Y não nos diz muito a respeito dos seus valores) além de limitar seu suporte. Ou seja,

$$\begin{aligned}
P(x_1, \dots, x_T, y_1, \dots, y_T \mid z_1, \dots, z_T, \theta_1, \theta_2) &= \prod_{i=1}^T P(x_i, y_i \mid z_i, \theta_1, \theta_2) \propto \\
&\propto \prod_{i=1}^T \left[\binom{m_i}{x_i} \theta_1^{x_i} (1 - \theta_1)^{m_i - x_i} \binom{n_i}{z_i - x_i} \theta_2^{z_i - x_i} (1 - \theta_2)^{n_i - z_i + x_i} \right] \mathbb{1}_{\{x_i + y_i = z_i\}} \quad (36)
\end{aligned}$$

Esse passo, na prática, constitui um problema para a aplicação direta do *Gibbs Sampling* a esse problema pois não conseguimos amostrar diretamente da distribuição apresentada em 36. Para contornar esse problema, podemos propor um *Rejection Sampling*. Apesar de não sabermos amostrar dessa distribuição, sabemos como avaliá-la para realizações $(X_i = x_i, Y_i = y_i \mid Z_i = z_i, \theta_1, \theta_2)$.

Para esse caso, o algoritmo de *Rejection Sampling* funcionaria da seguinte forma:

- (1) Dado um valor de Z , digamos $Z = k$, execute os passos a seguir.
- (2) Amostre θ_1 e $\theta_2 \sim \mathcal{U}_{[0,1]}$.
- (3) Com os valores de θ_1 e θ_2 , amostre $X \sim \text{Binomial}(m, \theta_1)$ e $Y \sim \text{Binomial}(n, \theta_2)$.
- (4) Se $X + Y \neq k$, rejeitamos X e Y e repetimos o passo (3). Caso contrário, aceitamos X e Y .
- (5) Uma vez aceito o par (X, Y) , atualizamos θ_1 e θ_2 em 36 e repetimos o processo a partir do passo (3).

Simulation question (Normal mixture model – Gibbs sampling)

1.

Considere um vetor aleatório $Z = \{Z_1, \dots, Z_N\}$ que assume valores em $\{1, \dots, K\}^N$ tal que

$$\mathbb{P}(Z = z | p) = \prod_{i=1}^N \mathbb{P}(Z_i = z_i | p) = \prod_{i=1}^N p_{z_i}$$

e considere o vetor $X = \{X_1, \dots, X_N\}$ tal que

$$X_i | Z_i = z_i, p, \mu, \sigma^2 \sim \mathcal{N}(\mu_{z_i}, \sigma_{z_i}^2), \quad \forall i \in \{1, \dots, N\}.$$

Primeiramente, vamos determinar a distribuição conjunta de X_i e Z_i , dados os valores dos parâmetros, i.e., encontrar $f(x_i, z_i | p, \mu, \sigma^2)$. Note que:

$$f(x_i, z_i | p, \mu, \sigma^2) = P(Z_i = z_i | p, \mu, \sigma^2) \cdot f(x_i | Z_i = z_i, p, \mu, \sigma^2) \quad (37)$$

considerando $X_i \perp\!\!\!\perp Z_i$ e atentando para o fato de que X_i é uma v.a. contínua, enquanto Z_i é uma v.a. discreta. Como estamos particularmente interessados na distribuição de X_i , vamos integrar 37 com relação a Z_i . Como Z_i é discreta, isso equivale a tomar o somatório em todo o suporte de Z_i . Assim,

$$f(x_i | p, \mu, \sigma^2) = \sum_{j=1}^K P(Z_i = j | p, \mu, \sigma^2) f(x_i | Z_i = z_i, p, \mu, \sigma^2) \quad (38)$$

Conforme o enunciado, se fizermos $P(Z_i = k | p) = p_k$, temos:

$$f(x_i | p, \mu, \sigma^2) = \sum_{j=1}^K p_j \phi(x_i; \mu, \sigma^2) \quad (39)$$

Onde ϕ é a PDF de uma v.a. Gaussiana. De 39, concluímos que o vetor aleatório X também segue um modelo de misturas de Gaussianas.

2.

Ora,

$$\begin{aligned} P(Z = z | x, p, \mu, \sigma^2) &\propto P(Z = z | p, \mu, \sigma^2) \cdot f(x | Z = z, p, \mu, \sigma^2) \propto \\ &\propto \prod_{i=1}^N P(Z_i = z_i | p) \cdot f(x_i | Z_i = z_i, p, \mu, \sigma^2) \propto \prod_{i=1}^N p_{z_i} \phi(x_i; \mu_{z_i}, \sigma_{z_i}^2) \end{aligned} \quad (40)$$

Portanto,

$$P(Z = z | x, p, \mu, \sigma^2) \propto p_z \frac{1}{\sqrt{2\pi\sigma_z^2}} \exp\left\{-\frac{1}{2\sigma_z^2}(x_i - \mu_z)^2\right\} \quad (41)$$

Podemos, então, amostrar diretamente da distribuição em 41 para cada Z_i , $i \in \{1, \dots, N\}$ e, depois, normalizar essas probabilidades (para que a densidade, de fato, integre 1).

3.

Analogamente ao item 2, sabemos que

$$\pi(p | x, Z = z, \mu, \sigma^2) \propto \pi(p) f(x, z | p, \mu, \sigma^2)$$

Logo,

$$\begin{aligned} \pi(p \mid x, z, \mu, \sigma^2) &\propto \pi(p) \prod_{i=1}^N f(x_i, z_i \mid p, \mu, \sigma^2) \propto \pi(p) \prod_{i=1}^N P(Z_i = z_i) \cdot f(x_i \mid Z_i = z_i, p, \mu, \sigma^2) \propto \\ &\propto \pi(p) \prod_{i=1}^N p_{z_i} \phi(x_i; \mu_{z_i}, \sigma_{z_i}^2) \propto \pi(p) \prod_{j=1}^K p_j^{(\#I)} \end{aligned} \quad (42)$$

onde $I = \{i : z_i = j\}$. Como $\pi(p) \propto \prod_{i=1}^N p_i^{\gamma_i - 1}$, podemos reescrever 42 como:

$$\pi(p \mid x, z, \mu, \sigma^2) \propto \prod_{j=1}^K p_j^{\gamma_j - 1 + (\#I)} \quad (43)$$

Amostrar dessa distribuição é equivalente a amostrar de uma gamma com parâmetros γ_j e 1, i.e., podemos amostrar v.a.'s $V_j \sim \mathcal{Gamma}(\gamma_j, 1)$ (note que os demais termos da PDF Gamma serão eliminados pela constante de proporcionalidade \propto).

4.

Como já fizemos nos outros itens, vamos aplicar a fórmula de Bayes

$$\pi(\mu \mid x, z, p, \sigma^2) \propto \pi(\mu) f(x, z \mid p, \mu, \sigma^2).$$

Assim, se considerarmos $\pi(\mu) = \mathcal{N}(m, \tau^2)$ (conforme mencionado no item 2), temos

$$\pi(\mu \mid x, z, p, \sigma^2) \propto \prod_{j=1}^K \exp \left\{ -\frac{1}{2\tau^2} (\mu_j - m)^2 \right\} \prod_{i=1}^N p_{z_i} \exp \left\{ -\frac{1}{2\sigma_{z_i}^2} (x_i - \mu_{z_i})^2 \right\} \quad (44)$$

Portanto, é fácil ver que

$$\pi(\mu_j \mid x, z, p, \sigma^2) \propto \prod_{j=1}^K \exp \left\{ -\frac{1}{2\tau^2} (\mu_j - m)^2 \right\} \prod_{i=1}^N p_{z_i} \exp \left\{ -\frac{1}{2\sigma_{z_i}^2} (x_i - \mu_{z_i})^2 \right\} \Big|_{z_i=j} \quad (45)$$

Como $\pi(\mu)$ é uma priori Gaussiana, sabemos que a posteriori de μ será $\mathcal{N}(\eta, \zeta^2)$ tal que:

$$\eta = \frac{m\tau^{-2} + \sum_{i=1}^N x_i \sigma_{z_i}^2}{\tau^{-2} + \sigma_{z_i}^2 (\#I)} \Big|_{z_i=j} \quad \text{e} \quad \zeta^2 = \tau^{-2} + (\#I) \sigma_{z_i}^{-2} \Big|_{z_i=j}$$

onde $(\#I)$ denota o número de índices para os quais $z_i = j$, i.e., a cardinalidade do conjunto $I = \{i : z_i = j\}$. Assim,

$$\pi(\mu_j \mid x, z, p, \sigma^2) \propto \exp \left\{ -\frac{1}{2} \left(\tau^{-2} + (\#I) \sigma_j^{-2} \right) \cdot \left(\mu_j - \frac{m\tau^{-2} + \sum_{i=1}^N x_i \sigma_j^2}{\tau^{-2} + \sigma_j^2 (\#I)} \right)^2 \right\}. \quad (46)$$

Trivialmente, podemos amostrar diretamente de $\mathcal{N}(\eta, \zeta^2)$.

5.

Do item 2, temos a priori:

$$\pi(\sigma_k^2) \propto (\sigma_k^2)^{-\alpha-1} \exp \{ -\beta \sigma_k^{-2} \} \quad (47)$$

E, da fórmula de Bayes,

$$\pi(\sigma^2 | x, z, p, \mu) \propto \pi(\sigma^2) \cdot f(x, z | p, \mu, \sigma^2) \quad (48)$$

Substituindo os devidos termos em 48, temos:

$$\pi(\sigma^2 | x, z, p, \mu) \propto \prod_{j=1}^K (\sigma_j^2)^{-\alpha-1} \exp\{-\beta\sigma_j^{-2}\} \cdot \prod_{i=1}^N \frac{p_{z_i}}{\sqrt{2\pi\sigma_{z_i}^2}} \exp\left\{-\frac{1}{2\sigma_{z_i}^2}(x_i - \mu_{z_i})^2\right\} \quad (49)$$

Assim, para cada $j \in \{1, \dots, N\}$, temos:

$$\begin{aligned} \pi(\sigma_j^2 | x, z, p, \mu) &\propto \prod_{j=1}^K (\sigma_j^2)^{-\alpha-1} \exp\{-\beta\sigma_j^{-2}\} \cdot \prod_{i=1}^N \frac{p_{z_i}}{\sqrt{2\pi\sigma_{z_i}^2}} \exp\left\{-\frac{1}{2\sigma_{z_i}^2}(x_i - \mu_{z_i})^2\right\} \Bigg|_{z_i=j} \propto \\ &\propto \prod_{j=1}^K (\sigma_j^2)^{-\alpha-1} \exp\{-\beta\sigma_j^{-2}\} \cdot \prod_{i=1}^N \frac{p_j}{\sqrt{2\pi\sigma_j^2}} \exp\left\{-\frac{1}{2\sigma_j^2}(x_i - \mu_j)^2\right\} \propto \\ &\propto \prod_{j=1}^K (\sigma_j^2)^{-\alpha-1-(\#I)/2} \exp\left\{-\beta - \sum_{i=1}^N \frac{1}{2\sigma_j^2}(x_i - \mu_j)^2\right\} = \\ &= \prod_{j=1}^K (\sigma_j^2)^{-(\alpha+(\#I)/2)-1} \exp\left\{-\left(\beta + \frac{1}{2} \sum_{i=1}^N (x_i - \mu_j)^2\right) \frac{1}{\sigma_j^2}\right\} \end{aligned} \quad (50)$$

Assim, podemos dizer que $\pi(\sigma_j^2 | x, z, p, \mu) \sim \text{InverseGamma}\left(\alpha + (\#I)/2, \beta + \frac{1}{2} \sum_{i=1}^N (x_i - \mu_j)^2\right)$. Como o próprio nome da distribuição sugere, podemos amostrar $U \sim \text{Gamma}$ com os mesmos parâmetros e, em seguida, tomar o inverso $1/U$.

6.

Estamos interessados em amostrar (y_1, \dots, y_N) de uma mistura de Gaussianas, com K (número de distribuições) fixo. Isto é, queremos formar uma amostra com base no seguinte modelo:

$$y_i = f(x_i) = \sum_{j=1}^K p_j \phi(x_i; \mu_j, \sigma_j^2), \quad i = 1, \dots, N. \quad (51)$$

A seguir, é apresentado um gráfico para uma mistura de 4 Gaussianas, com parâmetros:

- $p = (0.25, 0.25, 0.25, 0.25)$
- $\mu = (-6, -2, 2, 6)$
- $\sigma^2 = (1, 1, 1, 1)$
- $N = 10000$




Figura 1: Mistura de 4 gaussianas com parâmetros $p = (0.25, 0.25, 0.25, 0.25)$, $\mu = (-6, -2, 2, 6)$ e $\sigma^2 = (1, 1, 1, 1)$.

7.

Dados os valores de $Y = (y_1, \dots, y_N)$ do item anterior, estamos agora interessados em amostrar da distribuição posteriori. Para isso, vamos tomar como base as seguintes prioris, com os respectivos valores apontados para seus hiperparâmetros:

- Priori de p : $\pi(p) \propto \prod_{k=1}^K p_k^{\gamma_k - 1}$, com $\gamma_k = 1$, $\forall k \in \{1, \dots, K\}$.
- Priori de μ_k : $\pi(\mu_k) \propto \exp \left\{ -\frac{1}{2\tau^2} (\mu_k - m)^2 \right\}$, com $\mu_k = 0$ e $\tau^2 = 10$, isto é, $\mu_k \sim \mathcal{N}(0, 10)$.
- Priori de σ_k^2 : $\pi(\sigma_k^2) = (\sigma_k^2)^{-\alpha-1} \exp \left\{ -\beta \sigma_k^{-2} \right\}$, com $\alpha = 1$ e $\beta = 0.1$.

O valor desses hiperparâmetros foi escolhido de maneira tal que tenhamos prioris não informativas em cada caso.

8.

Começamos com valores iniciais para os parâmetros de interesse, com base nas distribuições *priori* e, a cada passo, são atualizadas as distribuições condicionais de Z , p , μ e σ^2 .

Para cada parâmetro p , μ e σ , são apresentados os gráficos das distribuições *priori*, *posteriori* e da cadeia de Markov construída por meio do algoritmo de *Gibbs Sampling*. Vemos que, em cada caso, as distribuições posteriores têm centro de massa concentrados em torno dos valores verdadeiros do parâmetro, definidos no item (6).

- Parâmetro p verdadeiro: $(0.25, 0.25, 0.25, 0.25)$. Os resultados da simulação são apresentados a seguir.




Figura 2: Priori de p , com $\gamma = (1, 1, 1, 1)$




Figura 3: Posteriori de p







Figura 4: Cadeia de p

- Parâmetros μ verdadeiros: $(-6, -2, 2, 6)$. De forma análoga, os resultados da simulação são apresentados a seguir:

Figura 5: Priori de μ Figura 6: Posteriores de μ , com $(m = 0, \tau = 10)$ Figura 7: Cadeia de μ

- Por fim, os parâmetros σ^2 verdadeiros são $(1, 1, 1, 1)$ e os resultados da simulação foram:




Figura 8: Priori de σ^2 , com $(\alpha = 1, \beta = 0.1)$




Figura 9: Posteriori de σ^2




Figura 10: Cadeia de σ^2