

## Lista de Exercícios 3

Professor(a): Eduardo Mendes

Aluno: Franklin Alves de Oliveira

## Exercise 1 (Gibbs Sampler)

1.

Segundo o enunciado, temos  $K_{X,Y}^S((x,y), (x',y'))$  como a matriz de transição (kernel) tomando como ponto de partida o par  $(x,y)$  e ponto de chegada  $(x',y')$  em  $S$  passos. Isto é,  $K_{X,Y}^S((x,y), (x',y'))$  denota a probabilidade de chegarmos em  $(x',y')$  a partir de  $(x,y)$ , tomando apenas  $S$  passos.

Considerando que, no *Gibbs Sampler* sistemático, amostramos primeiro de  $\pi_{Y|X}(\cdot | X^{(t-1)})$  e depois de  $\pi_{X|Y}(\cdot | Y^{(t)})$ , temos que

$$K_{X,Y}^S((x,y), (x',y')) = P((x',y') | (x,y), S) = \pi_{Y|X}(y' | x) \cdot \pi_{X|Y}(x' | y') \quad (1)$$

Agora, suponha, por contradição, que  $K_{X,Y}^S$  é reversível em relação a  $\pi_{X,Y}$ . Sob esse pressuposto, temos que:

$$\pi_{X,Y}(x,y) K_{X,Y}^S((x,y), (x',y')) = \pi_{X,Y}(x',y') K_{X,Y}^S((x',y'), (x,y)) \quad (2)$$

No entanto, note que, se reescrevermos 2 e usarmos a informação em 1,

$$\frac{\pi_{X,Y}(x,y) \cdot K_{X,Y}^S((x,y), (x',y'))}{\pi_{X,Y}(x',y') \cdot K_{X,Y}^S((x',y'), (x,y))} = \frac{\pi_{X,Y}(x,y) \cdot \pi_{Y|X}(y' | x) \cdot \pi_{X|Y}(x' | y')}{\pi_{X,Y}(x',y') \cdot \pi_{Y|X}(y | x') \cdot \pi_{X|Y}(x | y)} \quad (3)$$

Como

$$\pi_{X|Y}(x | y) = \frac{\pi_{X,Y}(x,y)}{\pi_Y(y)} \quad \text{e} \quad \pi_{X|Y}(x' | y') = \frac{\pi_{X,Y}(x',y')}{\pi_Y(y')},$$

temos que

$$\frac{\pi_{X,Y}(x,y) \cdot K_{X,Y}^S((x,y), (x',y'))}{\pi_{X,Y}(x',y') \cdot K_{X,Y}^S((x',y'), (x,y))} = \frac{\pi_Y(y) \cdot \pi_{Y|X}(y' | x)}{\pi_Y(y') \cdot \pi_{Y|X}(y | x')}. \quad (4)$$

A razão em 4, não necessariamente, é igual a 1  $\forall x, y \in \mathbb{X}$ , onde  $\mathbb{X}$  é o espaço de estados (para ver isso, note que, se  $y \neq y'$ , então  $\pi_Y(y) \neq \pi_Y(y')$ ). Com isso, concluímos que  $K_{X,Y}^S$  não é reversível (i.e., é irreversível) com relação a  $\pi_{X,Y}$ .  $\square$

2.

Do item 1 equação 1, sabemos que  $K_{X,Y}^S((x,y), (x',y')) = \pi_{Y|X}(y' | x) \cdot \pi_{X|Y}(x' | y')$ . Partindo dessa relação e integrando ambos os lados com relação a  $y'$ , obtemos:

$$\int K_{X,Y}((x,y), (x',y')) dy' = \int \pi_{Y|X}(y' | x) \cdot \pi_{X|Y}(x' | y') dy' \quad (5)$$

Analisando o lado direito, vemos que 5 independe do ponto de partida  $y$  e do ponto de chegada  $y'$ . Assim, temos que  $(X^{(t)})_{t \geq 1}$  é um processo de Markov, cujo Kernel é caracterizado como:

$$K_X(x, x') = \int \pi_{Y|X}(y' | x) \cdot \pi_{X|Y}(x' | y') dy' \quad (6)$$

Ainda resta mostrar que  $(X^{(t)})_{t \geq 1}$  é  $\pi_X$ -reversível, i.e., que  $\pi_X(x)K_X(x, x') = \pi_X(x')K(x', x)$ . De maneira esperta, vamos multiplicar ambos os lados por  $\pi_X(x) > 0$ . Assim,

$$\pi_X(x) \cdot K_X(x, x') = \pi_X(x) \cdot \int \pi_{Y|X}(y' | x) \cdot \pi_{X|Y}(x' | y') dy' \quad (7)$$

Ainda, pela regra de Bayes, podemos escrever:

$$\begin{aligned} \pi_X(x) \cdot K_X(x, x') &= \pi_X(x) \cdot \int \frac{\pi_{X|Y}(x | y') \cdot \pi_Y(y')}{\pi_X(x)} \cdot \frac{\pi_{Y|X}(y' | x') \cdot \pi_X(x')}{\pi_Y(y')} dy' = \\ &= \pi_X(x') \cdot \int \pi_{X|Y}(x | y') \cdot \pi_{Y|X}(y' | x') dy' = \pi_X(x') \cdot K_X(x', x) \end{aligned} \quad (8)$$

Logo,  $(X^{(t)})_{t \geq 1}$  é  $\pi_X$ -reversível, como queríamos demonstrar.  $\square$

### 3.

Como no *Random Scan Gibbs Sampler* temos 1/2 de chance de amostrarmos de  $\pi_{Y|X}(\cdot | X^{(t-1)})$  ou de  $\pi_{X|Y}(\cdot | Y^{(t-1)})$ , e também setamos  $X^{(t)} = X^{(t-1)}$  e  $Y^{(t)} = Y^{(t-1)}$  respectivamente, temos:

$$K_{X,Y}^R((x, y), (x', y')) = \frac{1}{2} \pi_{Y|X}(y' | x) \delta_X(x') + \frac{1}{2} \pi_{X|Y}(x' | y) \delta_Y(y'), \quad (9)$$

onde  $\delta_X(x')$  é a função massa de *Dirac*<sup>1</sup> aplicada no ponto  $x'$  e a mesma coisa vale para  $\delta_Y(y')$ , isto é,

$$\delta_X(x') = \begin{cases} 1, & \text{se } x = x' \\ 0, & \text{caso contrário} \end{cases} \quad \text{e} \quad \delta_Y(y') = \begin{cases} 1, & \text{se } y = y' \\ 0, & \text{caso contrário} \end{cases}$$

Agora, vamos mostrar que  $K_{X,Y}^R$  é  $\pi_{X,Y}$ -reversível. Para isso, vamos multiplicar ambos os lados de 9 por  $\pi_{X,Y}(x, y)$ . Assim,

$$\pi_{X,Y}(x, y) K_{X,Y}^R((x, y), (x', y')) = \pi_{X,Y}(x, y) \left[ \frac{1}{2} \pi_{Y|X}(y' | x) \delta_X(x') + \frac{1}{2} \pi_{X|Y}(x' | y) \delta_Y(y') \right] \quad (10)$$

Agora, perceba que

$$\begin{aligned} \pi_{X,Y}(x, y) \pi_{Y|X}(y' | x) \delta_X(x') &= \pi_{X,Y}(x', y) \pi_{Y|X}(y' | x) \delta_X(x') \\ &= \pi_X(x') \pi_{Y|X}(y | x') \pi_{Y|X}(y' | x) \delta_X(x') \\ &= \pi_{X,Y}(x', y') \pi_{Y|X}(y | x') \delta_X(x') \end{aligned} \quad (11)$$

e, de maneira análoga,

$$\begin{aligned} \pi_{X,Y}(x, y) \pi_{X|Y}(x' | y) \delta_Y(y') &= \pi_{X,Y}(x, y') \pi_{X|Y}(x' | y) \delta_Y(y') \\ &= \pi_Y(y') \pi_{X|Y}(x | y') \pi_{X|Y}(x' | y) \delta_Y(y') \\ &= \pi_{X,Y}(x', y') \pi_{X|Y}(x | y') \delta_Y(y') \end{aligned} \quad (12)$$

Substituindo 11 e 12 em 10,

---

<sup>1</sup>tomada com base nas notas de aula

$$\begin{aligned}
\pi_{X,Y}(x,y) K_{X,Y}^R((x,y),(x',y')) &= \frac{1}{2} \pi_{X,Y}(x',y') \pi_{Y|X}(y | x') \delta_X(x') + \frac{1}{2} \pi_{X,Y}(x',y') \pi_{X|Y}(x | y') \delta_Y(y') = \\
&= \pi_{X,Y}(x',y') \left[ \frac{1}{2} \pi_{Y|X}(y | x') \delta_X(x') + \frac{1}{2} \pi_{X|Y}(x | y') \delta_Y(y') \right] \\
&= \pi_{X,Y}(x',y') K_{X,Y}^R((x',y'),(x,y)), \tag{13}
\end{aligned}$$

exatamente como queríamos demonstrar.  $\square$

## Exercise 2 (Metropolis-within-Gibbs)

**1.**

Nesse caso, vamos calcular a probabilidade  $\alpha$  de aceitação nesse algoritmo.

$$\alpha \left( X_1 \mid X_1^{(t-1)}, X_2^{(t-1)} \right) = \min \left\{ 1, \frac{\pi \left( X_1, X_2^{(t-1)} \right) q \left( X_1^{(t-1)} \mid X_1, X_2^{(t-1)} \right)}{\pi \left( X_1^{(t-1)}, X_2^{(t-1)} \right) q \left( X_1 \mid X_1^{(t-1)}, X_2^{(t-1)} \right)} \right\} \quad (14)$$

Se tomarmos  $q(x'_1 \mid x_1, x_2) = \pi_{X_1|X_2}(x'_1 \mid x_2)$  em 14, temos:

$$\begin{aligned} \alpha \left( X_1 \mid X_1^{(t-1)}, X_2^{(t-1)} \right) &= \min \left\{ 1, \frac{\pi \left( X_1, X_2^{(t-1)} \right) \pi_{X_1|X_2} \left( X_1^{(t-1)} \mid X_1, X_2^{(t-1)} \right)}{\pi \left( X_1^{(t-1)}, X_2^{(t-1)} \right) \pi_{X_1|X_2} \left( X_1 \mid X_1^{(t-1)}, X_2^{(t-1)} \right)} \right\} = \\ &= \min \left\{ 1, \frac{\pi \left( X_1, X_2^{(t-1)} \right) \pi_{X_1|X_2} \left( X_1^{(t-1)} \mid X_2^{(t-1)} \right)}{\pi \left( X_1^{(t-1)}, X_2^{(t-1)} \right) \pi_{X_1|X_2} \left( X_1 \mid X_2^{(t-1)} \right)} \right\} \end{aligned} \quad (15)$$

Pela regra de Bayes, podemos reescrever 15 como:

$$\begin{aligned} \alpha \left( X_1 \mid X_1^{(t-1)}, X_2^{(t-1)} \right) &= \min \left\{ 1, \frac{\pi_{X_2} \left( X_2^{(t-1)} \right) \pi_{X_1|X_2} \left( X_1 \mid X_2^{(t-1)} \right) \pi_{X_1|X_2} \left( X_1^{(t-1)} \mid X_2^{(t-1)} \right)}{\pi_{X_2} \left( X_2^{(t-1)} \right) \pi_{X_1|X_2} \left( X_1^{(t-1)} \mid X_2^{(t-1)} \right) \pi_{X_1|X_2} \left( X_1 \mid X_2^{(t-1)} \right)} \right\} = \\ &= \min\{1, 1\} = 1. \end{aligned} \quad (16)$$

**2.**

O kernel, nesse caso (tomando como base as notas de aula), é dado por:

$$K \left( (x_1, x_2), (x'_1, x'_2) \right) = \left[ \alpha \left( x'_1 \mid x_1, x_2 \right) q \left( x'_1 \mid x_1, x_2 \right) + (1 - I(x_1, x_2)) \delta_{x_1}(x'_1) \right] \pi_{X_2|X_1} \left( x'_2 \mid x'_1 \right), \quad (17)$$

com  $I(x_1, x_2) = \int \alpha(y \mid x_1, x_2) \cdot q(y \mid x_1, x_2) dy$ .

Logo,

$$\begin{aligned} &\int \int \pi(x_1, x_2) K \left( (x_1, x_2), (x'_1, x'_2) \right) dx_1 dx_2 = \\ &\int \int \pi_{X_2}(x_2) \pi_{X_1|X_2}(x_1 \mid x_2) \left\{ \alpha(x'_1 \mid x_1, x_2) q(x'_1 \mid x_1, x_2) + (1 - I(x_1, x_2)) \delta_{x_1}(x'_1) \right\} \pi_{X_2|X_1}(x'_2 \mid x'_1) dx_1 dx_2 = \\ &= \int \pi_{X_2}(x_2) \left[ \int \pi_{X_1|X_2}(x_1 \mid x_2) \left\{ \alpha(x'_1 \mid x_1, x_2) q(x'_1 \mid x_1, x_2) + \right. \right. \\ &\quad \left. \left. + (1 - I(x_1, x_2)) \delta_{x_1}(x'_1) \right\} dx_1 \right] \pi_{X_2|X_1}(x'_2 \mid x'_1) dx_2 = \\ &\int \pi_{X_2}(x_2) \pi_{X_1|X_2}(x'_1 \mid x_2) \pi_{X_2|X_1}(x'_2 \mid x'_1) dx_2 = \\ &\int \pi(x'_1, x_2) \pi_{X_2|X_1}(x'_2 \mid x'_1) dx_2 = \\ &\pi_{X_1}(x'_1) \pi_{X_2|X_1}(x'_2 \mid x'_1) = \pi(x'_1, x'_2). \end{aligned} \quad (18)$$

□

### Exercise 3 (Metropolis-Hastings and Gibbs Sampler)

**1.**

Precisamos garantir que  $\pi(x)T(x, y) = \pi(y)T(y, x)$ , com  $x \neq y$ . Ou seja, isso equivale a mostrar que

$$\gamma(x, y) = \alpha(x, y) \pi(x) q(x, y) = \alpha(y, x) \pi(y) q(y, x) = \gamma(y, x) \quad (19)$$

Ora, mas essa relação é trivialmente satisfeita. Sendo assim, basta notar que 19 implica que

$$\begin{aligned} T(x, y) &= \alpha(x, y)q(x, y) + \left(1 - \sum \alpha(x, z)q(x, z)\right) \delta_x(y) \Rightarrow \\ T(x, y) &= \frac{\gamma(x, y)}{\pi(x)} + \left(1 - \sum \frac{\gamma(x, z)}{\pi(x)}\right) \delta_x(y). \end{aligned} \quad (20)$$

Analogamente,

$$T(y, x) = \frac{\gamma(y, x)}{\pi(y)} + \left(1 - \sum \frac{\gamma(y, z)}{\pi(y)}\right) \delta_y(x). \quad (21)$$

Agora, é fácil ver que

$$\pi(x)T(x, y) = \gamma(x, y) + \left(1 - \sum \gamma(x, z)\right) \delta_x(y) \quad (22)$$

e

$$\pi(y)T(y, x) = \gamma(y, x) + \left(1 - \sum \gamma(y, z)\right) \delta_y(x) \quad (23)$$

Como estamos interessados no caso em que  $x \neq y$ <sup>2</sup>, temos que  $\delta_y(x) = \delta_x(y) = 0$ . Logo, temos que (22) = (23), i.e.,

$$\pi(x)T(x, y) = \pi(y)T(y, x), \text{ com } x \neq y \quad (24)$$

E, portanto,  $T$  é  $\pi$ -reversível.  $\square$

**2.**

A probabilidade de aceitação para o algoritmo de Metropolis-Hastings é dada por:

$$\alpha(x, y) = \min \left\{ 1, \frac{\pi(y)q(y, x)}{\pi(x)q(x, y)} \right\} \quad (25)$$

Se multiplicarmos ambos os lados por  $\pi(x)q(x, y)$ , obtemos:

$$\pi(x)q(x, y)\alpha(x, y) = \pi(x)q(x, y) \min \left\{ 1, \frac{\pi(y)q(y, x)}{\pi(x)q(x, y)} \right\} = \min \{ \pi(x)q(x, y), \pi(y)q(y, x) \} \quad (26)$$

Logo,

$$\gamma(x, y) = \min \{ \pi(x)q(x, y), \pi(y)q(y, x) \} \quad (27)$$

Para o algoritmo de Baker, vamos partir da relação

$$\gamma(x, y) = \frac{\pi(x)q(x, y)\pi(y)q(y, x)}{\pi(x)q(x, y) + \pi(y)q(y, x)} \quad (28)$$

e, dividindo ambos os lados por  $\pi(x)q(x, y)$ , é trivial ver que

---

<sup>2</sup>O caso em que  $x = y$  é trivialmente satisfeito

$$\begin{aligned}
\frac{\gamma(x, y)}{\pi(x)q(x, y)} &= \frac{\pi(x)q(x, y)\pi(y)q(y, x)}{\pi(x)q(x, y) + \pi(y)q(y, x)} \cdot \frac{1}{\pi(x)q(x, y)} = \\
&= \frac{\pi(y)q(y, x)}{\pi(x)q(x, y) + \pi(y)q(y, x)} = \frac{1}{1 + \frac{\pi(x)q(x, y)}{\pi(y)q(y, x)}}.
\end{aligned} \tag{29}$$

□

**3.**

Tome  $x \neq y$ . Vamos comparar o kernel do algoritmo de Metropolis-Hastings ( $T_{M-H}$ ) com o kernel do algoritmo de Baker ( $T_{Baker}$ ).

$$T_{M-H} = \alpha(x, y)q(x, y) = \frac{\gamma(x, y)}{\pi(x)} \tag{30}$$

Usando um dos resultados do item 2,

$$T_{M-H}(x, y) = \frac{\min\{\pi(x)q(x, y), \pi(y)q(y, x)\}}{\pi(x)} \tag{31}$$

Agora, para o algoritmo de Baker:

$$T_{Baker}(x, y) = \alpha(x, y)q(x, y) = \frac{\gamma(x, y)}{\pi(x)} = \frac{1}{\pi(x)} \frac{\pi(x)q(x, y)\pi(y)q(y, x)}{\pi(x)q(x, y) + \pi(y)q(y, x)} \tag{32}$$

Sem perda de generalidade, vamos supor que  $\pi(x)q(x, y) \leq \pi(y)q(y, x)$ .<sup>3</sup> Nesse caso,

$$T_{M-H}(x, y) = \frac{\pi(x)q(x, y)}{\pi(x)} = q(x, y) \tag{33}$$

e

$$T_{Baker} = \frac{q(x, y)\pi(y)q(y, x)}{\pi(x)q(x, y) + \pi(y)q(y, x)} = T_{M-H} \cdot \frac{\pi(y)q(y, x)}{\pi(x)q(x, y) + \pi(y)q(y, x)} \tag{34}$$

Agora, denote  $c = \frac{\pi(y)q(y, x)}{\pi(x)q(x, y) + \pi(y)q(y, x)} \leq 1$ . Assim, é fácil ver que

$$T_{Baker} = c \cdot T_{M-H} \leq T_{M-H} \tag{35}$$

Portanto, por 35 e pelo teorema enunciado nesse item, temos que o  $T_{M-H}$  possui menor variância assintótica. □

**4.**

A partir das definições dadas no enunciado, vamos determinar as matrizes de transição para os algoritmos *Random Scan Gibbs Sampler* (RSGS) e *Modified Random Scan Gibbs Sampler* (MRSGS). Primeiramente, para o *Random Scan Gibbs Sampler*, com  $x_k \neq y_k$ , temos:

$$T_{RSGS}(x, y) = \frac{\pi_{X_K|X_{-K}}(y_K | x_{-K}) \delta_{x_{-K}}(y_{-K})}{d} \tag{36}$$

onde  $d \sim \mathcal{D}Unif_{\{1, \dots, d\}}$ . Não obstante, para o *Modified Random Scan Gibbs Sampler*, temos:

$$T_{MRSGS}(x, y) = \frac{q(y_K | x_{-K})}{d} \cdot \min \left\{ 1, \frac{1 - \pi_{X_K|X_{-K}}(x_K | x_{-K})}{1 - \pi_{X_K|X_{-K}}(y_K | x_{-K})} \right\} \delta_{x_{-K}}(y_{-K}) =$$

---

<sup>3</sup>Todas as conclusões a seguir são análogas para o caso contrário.

$$\begin{aligned}
&= \frac{\pi_{X_K|X_{-K}}(y_K | x_{-K})}{d [1 - \pi_{X_K|X_{-K}}(x_K | x_{-K})]} \cdot \min \left\{ 1, \frac{1 - \pi_{X_K|X_{-K}}(x_K | x_{-K})}{1 - \pi_{X_K|X_{-K}}(y_K | x_{-K})} \right\} \delta_{x_{-K}}(y_{-K}) = \\
&= \frac{1}{d} \cdot \min \left\{ \frac{1}{1 - \pi_{X_K|X_{-K}}(x_K | x_{-K})}, \frac{1}{1 - \pi_{X_K|X_{-K}}(y_K | x_{-K})} \right\} \delta_{x_{-K}}(y_{-K}) \quad (37)
\end{aligned}$$

Note que, de 36 e 37, temos:

$$\begin{aligned}
\frac{T_{MRSGS}(x, y)}{T_{RSGS}(x, y)} &= \min \left\{ \frac{1}{1 - \pi_{X_K|X_{-K}}(x_K | x_{-K})}, \frac{1}{1 - \pi_{X_K|X_{-K}}(y_K | x_{-K})} \right\} \cdot \frac{1}{\pi_{X_K|X_{-K}}(y_K | x_{-K})} \Rightarrow \\
&\Rightarrow \frac{T_{MRSGS}(x, y)}{T_{RSGS}(x, y)} \geq \frac{1}{\pi_{X_K|X_{-K}}(y_K | x_{-K})}
\end{aligned}$$

Logo,

$$T_{MRSGS}(x, y) \geq \frac{T_{RSGS}(x, y)}{\pi_{X_K|X_{-K}}(y_K | x_{-K})} \Rightarrow T_{MRSGS}(x, y) \geq T_{RSGS}(x, y) \quad (38)$$

Uma vez que  $0 \leq \pi_{X_K|X_{-K}}(y_K | x_{-K}) \leq 1$ . Assim,

$$T_{MRSGS}(x, y) \geq T_{RSGS}(x, y) \quad (39)$$

Portanto, pelo teorema enunciado no item 3, o *Modified Random Scan Gibbs Sampler* apresenta a menor variância assintótica.  $\square$

## Exercise 4 (Metropolis-Hastings)

**1.**

Ora, a distribuição proposta  $q(x' | x)$  é, simplesmente, dada por:

$$q(x' | x) = \int g(x' | \theta) f(\theta | x) d\theta \quad (40)$$

Uma vez que  $\vartheta \sim f(\theta | X^{(t-1)})$  e estamos amostrando  $X \sim g(\cdot | \vartheta)$ . No entanto, a função  $f(\cdot | x)$  não é conhecida e, portanto, não podemos calcular diretamente a integral em 40.  $\square$

**2**

Considere, inicialmente, um algoritmo Metropolis-Hastings tradicional com distribuição *target* dada por

$$\tilde{\pi}(x, \theta) = \pi(x) f(\theta | x)$$

e distribuição proposta

$$q((x', \theta') | (x, \theta)) = g(x' | \theta) f(\theta' | x')$$

Assim, para mostrar que o kernel é  $\tilde{\pi}$ -invariante, temos que mostrar que:

$$\tilde{\pi}(x', \theta') q((x, \theta) | (x', \theta')) = \pi(x') g(x | \theta') \quad (41)$$

e

$$\tilde{\pi}(x, \theta) q((x', \theta') | (x, \theta)) = \pi(x) g(x' | \theta) \quad (42)$$

Para matar dois coelhos com uma só cajadada, vamos dividir 41 por 42, e obter

$$\frac{\tilde{\pi}(x', \theta') q((x, \theta) | (x', \theta'))}{\tilde{\pi}(x, \theta) q((x', \theta') | (x, \theta))} = \frac{\pi(x') f(\theta' | x') g(x | \theta') f(\theta | x)}{\pi(x) f(\theta | x) g(x' | \theta) f(\theta' | x')} = \frac{\pi(x') g(x | \theta')}{\pi(x) g(x' | \theta)} \quad (43)$$

mostrando, assim, que o kernel é  $\tilde{\pi}$ -invariante.

**3.**

Se decomposmos a função  $\min\{U, V\}$  como

$$\min\{U, V\} = \frac{U + V}{2} - \frac{|V - U|}{2} = U + \frac{V - U - |V - U|}{2}$$

podemos, então, escrever:

$$\mathbb{E}[\min\{U, V\}] = \mathbb{E}[U] + \mathbb{E}\left[\frac{V - U - |V - U|}{2}\right] = \mathbb{E}[U] + \frac{\mathbb{E}[V - U] - \mathbb{E}[|V - U|]}{2} \quad (44)$$

De 5, podemos destacar dois possíveis casos:

- (1) Se  $\mathbb{E}[U] \leq \mathbb{E}[V] \Rightarrow \mathbb{E}[V - U] \leq \mathbb{E}[|V - U|] \Rightarrow \mathbb{E}[\min\{U, V\}] = \mathbb{E}[U]$ ; caso contrário,
- (2) Se  $\mathbb{E}[U] > \mathbb{E}[V] \Rightarrow \mathbb{E}[V - U] > \mathbb{E}[|V - U|] \Rightarrow \mathbb{E}[\min\{U, V\}] = \mathbb{E}[V]$ .

Com isso, provamos o que foi pedido. □

**4.**

(Não consegui fazer!)



## Exercise 5 (Thinning of a Markov Chain)

**1.**

Seguindo a dica sugerida no exercício,

$$\begin{aligned} (Y - \alpha Z)^2 \geq 0 &\Rightarrow \mathbb{E}[(Y - \alpha Z)^2] \geq 0 \Rightarrow \mathbb{E}[Y^2 - 2\alpha YZ + (\alpha Z)^2] \geq 0 \Rightarrow \\ \mathbb{E}[Y^2] - \mathbb{E}[2\alpha YZ] + \mathbb{E}[\alpha^2 Z^2] &\geq 0 \Rightarrow \mathbb{E}[Y^2] - 2\alpha \mathbb{E}[YZ] + \alpha^2 \mathbb{E}[Z^2] \geq 0 \end{aligned} \quad (45)$$

Em 45 temos uma função quadrática em  $\alpha$ . Como sabemos que essa função é não-negativa, inferimos que:

$$\Delta = \sqrt{4\alpha^2 \cdot \mathbb{E}[YZ]^2 - 4\alpha^2 \cdot \mathbb{E}[Z^2] \mathbb{E}[Y^2]} \leq 0 \iff \mathbb{E}[YZ]^2 \leq \mathbb{E}[Z^2] \mathbb{E}[Y^2] \quad (46)$$

Exatamente como queríamos encontrar.  $\square$

**2.**

Ora,

$$\mathbb{Cov}[Y, Z] \leq |\mathbb{Cov}[Y, Z]| \Rightarrow \mathbb{Cov}[Y, Z] \leq \left| \mathbb{E}[(Y - \mathbb{E}[Y])(Z - \mathbb{E}[Z])] \right| \quad (47)$$

Aplicando a desigualdade de Cauchy-Schwarz (resultado do item 1), temos:

$$\mathbb{Cov}[Y, Z] \leq \sqrt{\mathbb{E}[(Y - \mathbb{E}[Y])^2] \cdot \mathbb{E}[(Z - \mathbb{E}[Z])^2]} = \mathbb{V}(Y) \quad (48)$$

Onde a última igualdade acontece se  $Z$  e  $Y$  têm distribuições marginais idênticas. Nesse caso,  $\mathbb{V}(Y) = \mathbb{V}(Z)$  e o resultado segue.  $\square$

**3.**

(Não consegui fazer!)

## Simulation question (Probit model – Gibbs and M-H)

1.

Seguindo a dica dada no exercício, vamos escolher  $\beta^T = [3, -1]$ ,  $n = 60$  (pequeno) e  $p = 2$ . Ainda, geramos a matriz de variáveis explicativas  $X_{n \times p}$  proveniente de duas distribuições normais, com médias e desvios-padrão  $\mu_1 = \frac{1}{2}$ ,  $\mu_2 = 1.5$ ,  $\sigma_1 = \sigma_2 = 1$ . Esses valores foram escolhidos para refletir uma turma de alunos onde um grupo tem média 2, e outro grupo média 5.

Assim, as observações sintéticas de  $Y$  geradas aleatoriamente foram:

$Y = 0$	$Y = 1$
32	28

Tabela 1: Amostra sintética de  $Y$ . ( $seed = 101$ )

2.

Continuando o exercício, vamos agora introduzir uma distribuição priori em  $\beta$ :

$$\pi(\beta) = \mathcal{N}(0, B)$$

onde  $B$  é uma matriz de covariâncias. Nesse exercício, tomamos

$$B = \begin{bmatrix} 2.5 & 0 \\ 0 & 2.5 \end{bmatrix}$$

Ainda, a função de verossimilhança é dada por:

$$P(Y_1 = y_1, \dots, Y_n = y_n \mid \beta) = \prod_{i=1}^n \Phi(X_i^T \beta)^{y_i} [1 - \Phi(X_i^T \beta)]^{1-y_i}$$

Com essas informações, foi criada uma função que tomava como *input* um vetor  $\beta$  e retornava como *output* o log da distribuição posterior avaliada em  $\beta$ .

3.

Em resposta a esse item, foi executado o algoritmo de Metropolis-Hastings com 150 mil iterações. Abaixo, são apresentados alguns gráficos para visualizarmos a cadeia (idealmente, a cadeia exploraria regiões mais próximas dos verdadeiros valores de  $\beta^T = [\beta_1, \beta_2] = [-1, 2.1]$ ).

A taxa de aceitação desse algoritmo foi de 15,08%.

Vemos que, conforme o esperado, esse algoritmo resultou em densidades mais concentradas em torno dos verdadeiros valores de  $\beta_1 = 3$  e  $\beta_2 = -1$  e que as cadeias convergiram para os mesmos valores.

4.

Tome  $Z_i \sim \mathcal{N}(X_i^T \beta, 1)$ ,  $\forall i = 1, \dots, n$ . Assim, podemos escrever a condicional

$$\pi(\beta, Z \mid Y) \propto \pi(\beta) \prod_{i=1}^n [\mathbb{1}_{\{Z_i < 0\}} \mathbb{1}_{\{Y_i = 0\}} + \mathbb{1}_{\{Z_i \geq 0\}} \mathbb{1}_{\{Y_i = 1\}}] \cdot \varphi(Z_i; X_i^T \beta, 1)$$

onde  $\varphi(Z_i; \cdot)$  denota a densidade Gaussiana avaliada no ponto  $Z_i$ . Como a priori de  $\beta$  também é normal, temos que a posteriori de  $\beta$  também é normal.




Figura 1: Cadeia




Figura 2: Evolução das cadeias




Figura 3: Densidade conjunta




Figura 4: Densidade conjunta + marginais

5.

Conforme sugerido na questão, foi feito o mesmo exercício, considerando agora um algoritmo *Gibbs Sampler*, onde amostramos de  $P(\beta | Z, Y)$  e de  $P(Z | \beta, Y)$ .

Assim como o algoritmo de *Metropolis-Hastings*, o algoritmo *Gibbs Sampler* apresentou maior concentração de massa em torno dos verdadeiros valores de  $\beta$ .




Figura 5: Cadeia




Figura 6: Evolução das cadeias




Figura 7: Densidade conjunta




Figura 8: Densidade conjunta + marginais

6.

Agora, vamos comparar os dois algoritmos verificando a autocorrelação serial.




Figura 9: Autocorrelação Serial

Nesse gráfico, é fácil ver que o algoritmo de *Metropolis-Hastings* retornou uma cadeia menos autocorrelacionada, o que é uma propriedade mais desejável.